Lire les mathématiques de l’IA

Reprendre les mathématiques dans son parcours professionnel

Jean-Pierre Morard

Guide mathématique de la collection *Les Grandes Idées des Réseaux*

Les ressources et travaux pratiques de la collection sont accessibles en ligne.

Une idée concrète. Un dessin. Une formule que l’on sait lire.

Une mesure à interpréter, une prévision à discuter, un modèle à entraîner : les mathématiques deviennent utiles quand elles éclairent une question que l’on se pose déjà.

Ce guide s’adresse à celles et ceux qui reprennent les mathématiques après plusieurs années de vie professionnelle. Savoir additionner, multiplier et diviser suffit pour commencer. Une formation en lettres ou en philosophie permet aussi d’y entrer : les habitudes de raisonnement sont utiles ; les gestes de calcul se reprennent pas à pas. Les fractions, les fonctions et les indices sont repris au fil des exemples.

L’IA n’est pas réservée aux docteurs. On peut apprendre à utiliser ses méthodes, comprendre leurs hypothèses et discuter leurs résultats à différentes étapes de son parcours.

L’objectif est de retrouver assez d’aisance pour ouvrir un article ou une thèse, déplier une équation et repérer ce qu’il reste à approfondir. Les pages de transition conduisent aux volumes de la collection ; les démonstrations spécialisées demanderont parfois un cours complémentaire.

Édition 1.10 - LGIR-NOTATIONS-1.10-20261014

© Jean-Pierre Morard, 2026. CC BY-NC-ND 4.0 : partage avec attribution, sans usage commercial ni diffusion de versions modifiées. Les ressources citées conservent leurs propres licences.

Un parcours que l’on peut reprendre à son rythme

Commencez par une question familière. Lisez l’exemple, cachez la formule, puis racontez le calcul avec vos mots. Retrouvez ensuite les symboles. Le lien entre les deux compte davantage que la récitation de l’alphabet grec.

Trois portes d’entrée

• Retrouver les bases : fonctions, indices, sommes, vecteurs et matrices.

• Comprendre les calculs de l’IA : variations, probabilités et optimisation.

• Ouvrir un texte scientifique : objectif d’apprentissage, rétropropagation, attention et hypothèses.

Le parcours principal contient 21 étapes. Les pages de transition ajoutent les calculs utiles aux dossiers du livre : on peut les reprendre lorsque le besoin apparaît. Chaque étape contient une question courte. Les réponses sont réunies à la fin pour laisser le temps de chercher. Après quelques jours, essayez de refaire un exemple sans regarder : ce qui résiste indique la page à reprendre.

Pour accompagner cette reprise, Céline De Luca propose une vidéo sur la façon d’apprendre. Choisissez une petite question et reliez l’exemple aux idées déjà comprises.

Un premier repérage

Que vaut 3^2 ? Que vaut la moyenne de 2 et 6 ? Si un coût augmente quand un réglage augmente, dans quel sens tenter une petite correction ?

Vous avez répondu 9, 4 et « réduire le réglage » ? Vous possédez déjà les idées de puissance, de moyenne et de descente. Ce guide leur donnera un langage plus précis.

À retenir. Pour chaque formule : que représente-t-elle, quelles sont ses entrées, que produit-elle et dans quelles conditions s’applique-t-elle ?

Votre fil conducteur. Un système reçoit des observations, les combine, prédit une sortie et ajuste ses réglages. Nous suivrons ces quatre gestes. Pour mesurer vos progrès, expliquez une formule à voix haute, puis faites le calcul sur d’autres nombres. Comprendre la phrase et savoir refaire le geste se complètent.

Pour choisir une transition, ouvrez les renvois vers la collection. Pour vérifier vos premiers calculs, retrouvez les réponses.

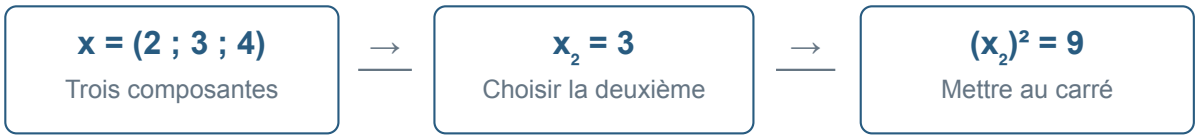
1. Les lettres ont un rôle

Une lettre évite de réécrire un nombre chaque fois qu'il change. Dans f(x) = 2x + 1, x est l'entrée et f(x) la sortie. Pour x = 3, on obtient 7. Les parenthèses indiquent ici l'entrée d'une fonction ; elles ne demandent pas de multiplier f par x.

$$f(3) = 2 \times 3 + 1 = 7$$

Un **paramètre** règle le modèle. Dans f(x) = wx + b, w et b restent fixés pendant une prédiction. L'entraînement peut ensuite les modifier.

Un indice choisit ; une puissance transforme.



Lire la position, puis l'opération : deux gestes distincts.

Lire un indice et un exposant : choisir une composante, puis effectuer une opération.

La liste x = (2 ; 3 ; 4) contient trois valeurs. x_2 choisit la deuxième : 3. Son carré vaut donc 9.

À retenir. Un indice repère ; une puissance transforme. Dans un réseau neuronal, un exposant entre parenthèses, comme $x^{(2)}$, peut désigner la couche 2 : la convention du texte décide.

À essayer 1. Avec x = (2 ; 3 ; 4), que valent x_3 et $(x_3)^2$? Avec w = 2 et b = 1, que vaut f(4) ?

Avant les formules : retrouver les gestes de calcul

Dans 2x + 1, le symbole × est sous-entendu : 2x signifie 2 × x. Les parenthèses regroupent ce qui doit être calculé ensemble. Un signe moins devant une parenthèse change le signe de chacun de ses termes : −(x − 3) = −x + 3.

Développer : multiplier chaque terme

Pour mettre x + h au carré, on multiplie les deux parenthèses. Chaque terme de la première multiplie chaque terme de la seconde.

$$(x+h)^2 = (x+h)(x+h) = x^2 + xh + hx + h^2 = x^2 + 2xh + h^2$$

Factoriser effectue le trajet inverse : 4h + h² = h(4 + h). Si h est non nul, diviser par h donne 4 + h. Ces deux gestes expliquent le calcul de la dérivée à venir.

Isoler une inconnue : garder l’égalité vraie

Si 2w + 1 = 7, on soustrait 1 des deux côtés : 2w = 6. Puis on divise les deux côtés par 2 : w = 3. On vérifie dans l’expression de départ : 2 × 3 + 1 = 7.

Une fraction a/b signifie a divisé par b, avec b non nul. Ainsi 6/2 = 3 et 1/2 = 0,5. Pour simplifier, on divise le numérateur et le dénominateur par un même facteur non nul : 6/8 = 3/4. On ne supprime pas un terme d’une addition : (x + 2)/x ne vaut pas 2.

À essayer — calcul. Développez (x + 1)² et résolvez 3w − 2 = 10. Réponses : x² + 2x + 1 et w = 4. Remplacez ensuite x par 2 pour vérifier le développement.

Fractions, puissances et unités : garder l’échelle

Un paquet de 1 500 octets contient 1 500 × 8 = 12 000 bits. Sur une liaison de 1 Mbit/s, sa transmission seule prend 12 000/1 000 000 = 0,012 seconde, soit 12 ms. Ce calcul ne compte ni attente ni propagation.

$$\frac{a}{b} + \frac{c}{d} = \frac{ad + bc}{bd} \qquad \frac{a}{b} \times \frac{c}{d} = \frac{ac}{bd} \quad (b \neq 0,\ d \neq 0)$$

Pour additionner 1/2 et 1/3, on exprime les parts dans la même unité : trois sixièmes plus deux sixièmes donnent 5/6. Multiplier par 1/2 revient à prendre la moitié ; diviser par 1/2 revient à multiplier par 2.

Une puissance négative donne un inverse : $10^{-3} = 1/10^{3} = 0{,}001$. Ainsi 3×10^{-3} seconde vaut 3 ms. Le préfixe méga signifie ici 10^{6} ; milli signifie 10^{-3}. Écrire $10^{0} = 1$ permet de garder les mêmes règles.

À retenir. Une égalité garde ses unités. Dans temps = volume/débit, bit/(bit/s) donne des secondes. Un taux de 8 % vaut 0,08 ; passer de 8 % à 10 % ajoute deux points de pourcentage, soit une hausse relative de 25 %.

À essayer — fractions. Un paquet contient 2 000 octets ; le débit vaut 2 Mbit/s. Calculez son temps de transmission en ms.

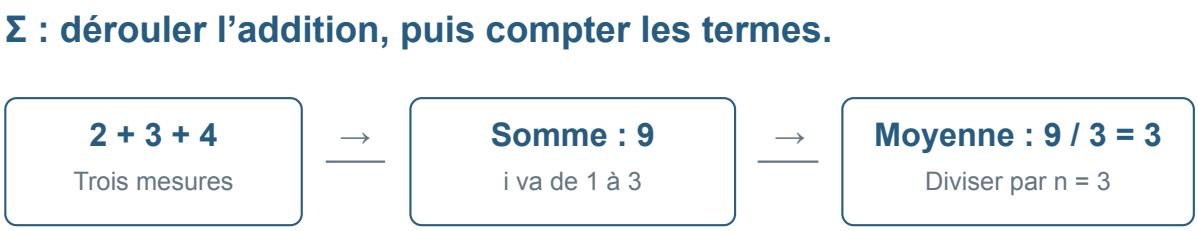
Correction — fractions. 2 000 × 8 = 16 000 bits ; 16 000/(2 × 10^{6}) = 0,008 s = 8 ms. La taille et le débit doivent être exprimés dans des unités compatibles.

2. Sigma : écrire une addition sans tout recopier

Supposons que trois mesures valent 2, 3 et 4. Leur somme vaut 9. La lettre grecque Σ, **sigma majuscule**, rassemble cette addition.

$$\sum_{i=1}^{3} x_i = x_1 + x_2 + x_3 = 2 + 3 + 4 = 9$$

i est un compteur : il prend successivement les valeurs 1, 2 et 3. Le nombre sous Σ indique le départ ; celui au-dessus indique l'arrivée. x_i précise ce que l'on additionne.



Une somme se déplie en trois termes ; diviser par le nombre de termes donne la moyenne.

La fraction 1/3 signifie « diviser par trois ». La moyenne vaut donc 9/3 = 3. Avec n mesures, le même geste s'écrit :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

La barre au-dessus de x désigne ici la moyenne. La lettre i peut être remplacée par j sans changer le résultat, si l'on remplace aussi l'indice dans x_i.

À essayer 2. Les écarts d'une prévision sont −2, 1 et 3. Quelle est la moyenne de leurs carrés ? Pourquoi ne suffit-il pas de calculer leur somme ?

3. Vecteurs et matrices : des listes et des tableaux

Un **scalaire** est un nombre. Un **vecteur** rassemble plusieurs nombres. Une **matrice** est un tableau de nombres organisé en lignes et colonnes.

Pour trois liaisons, on relève deux variables : charge et débit. Le tableau X a trois lignes, une par liaison, et deux colonnes, une par variable. On dit qu'il a la dimension 3 × 2.

Vérifier les dimensions avant de multiplier.



Les dimensions intérieures coïncident ; on obtient trois prévisions.

Les dimensions permettent de suivre un calcul : trois observations à deux variables donnent trois prévisions.

Prenons une seule ligne x = (2 ; 3) et deux poids w = (4 ; 1). Leur somme pondérée vaut :

$$w^\top x = 4 \times 2 + 1 \times 3 = 11$$

Le signe $^\top$, lu **transposée**, échange lignes et colonnes. Avec des vecteurs colonnes, $w^\top$ devient une ligne ; $w^\top x$ devient un scalaire.

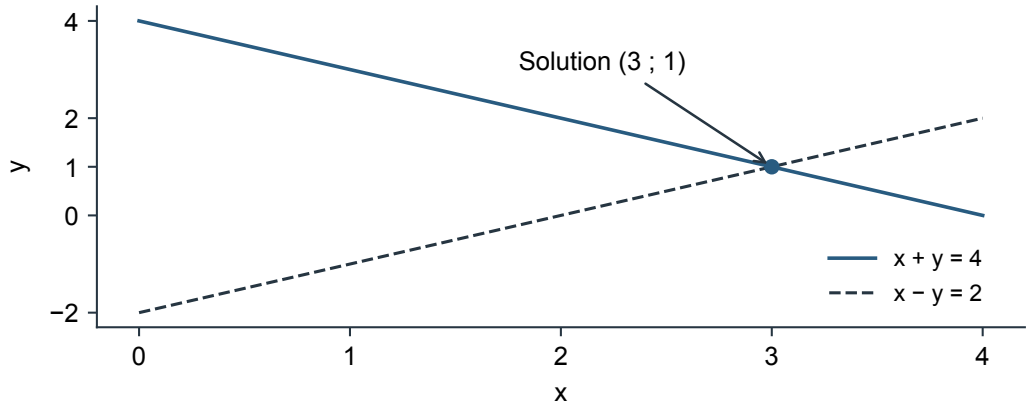
Le produit Xw applique cette même somme à chaque ligne de X. Si X est de dimension n × d et w de dimension d × 1, la sortie a la dimension n × 1.

À retenir. Le nombre de colonnes du premier facteur doit égaler le nombre de lignes du second.

À essayer 3. Un tableau contient 100 observations et 5 variables. Quelles sont les dimensions de X, de w et de Xw ?

Systèmes linéaires : plusieurs inconnues à la fois

Deux mesures donnent x + y = 4 et x − y = 2. Additionner les équations élimine y : 2x = 6, donc x = 3. La première donne ensuite y = 1. Ces deux valeurs doivent satisfaire les deux équations.



Les deux droites se croisent au point qui satisfait les deux équations.

$$Az = b, \qquad A = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad z = \begin{pmatrix} x \\ y \end{pmatrix}, \quad b = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$$

Chaque ligne de A représente une équation. La transformation est **linéaire** : A(uz + vt) = uAz + vAt pour des coefficients u et v. Ajouter un décalage fixe produit une transformation affine.

Pour une matrice carrée 2 × 2, le **déterminant** vaut :

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc$$

Ici il vaut −2 : A est inversible. Sa matrice inverse vaut $A^{-1} = A/2$; elle permet de retrouver $z = A^{-1}b$. Elle n’est pas la liste des inverses de chaque coefficient.

Si la seconde équation était 2x + 2y = 8, elle répéterait la première. Le déterminant serait nul ; on ne pourrait pas distinguer x de y. Avec 2x + 2y = 9, les équations seraient incompatibles. « Pas de solution unique » ne veut donc pas toujours dire « aucune solution ».

À retenir. Le rang compte les directions indépendantes. En calcul numérique, résoudre Az = b évite généralement de construire explicitement A^{-1}. Des mesures presque redondantes peuvent rendre le résultat très sensible au bruit.

À essayer — systemes. Résolvez x + y = 6 et x − y = 2. Donnez uniquement x.

Correction — systemes. L’addition donne 2x = 8, donc x = 4 ; puis y = 2. Vérifier les deux équations permet de contrôler le résultat.

4. Mesurer une taille : valeur absolue et norme

La **valeur absolue** |a| mesure la distance d'un nombre à zéro. |−3| = 3 et |3| = 3. On ne conserve pas le signe.

Pour un vecteur, la **norme euclidienne** mesure une longueur. Elle additionne les carrés des composantes, puis prend la racine carrée.

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2} \qquad \|(3,4)\|_2 = \sqrt{9+16} = 5$$

√25 vaut 5 : c'est le nombre positif dont le carré vaut 25. Les deux barres de la norme encadrent tout le vecteur.

Un indice qui ne compte pas les valeurs

Le 2 de $\|x\|_2$ désigne la règle de mesure utilisée. La norme 1 additionne les valeurs absolues : $\|(3,4)\|_1 = 7$. La norme 2 donne 5 pour ce même vecteur.

Dans une pénalité $\|w\|_2^2$, on met la norme au carré. Pour w = (3 ; 4), le résultat vaut 25, et non 5.

À retenir. On choisit une mesure adaptée au sens des variables. Additionner le carré d'un délai en millisecondes et celui d'une énergie en joules demande une mise à l'échelle justifiée.

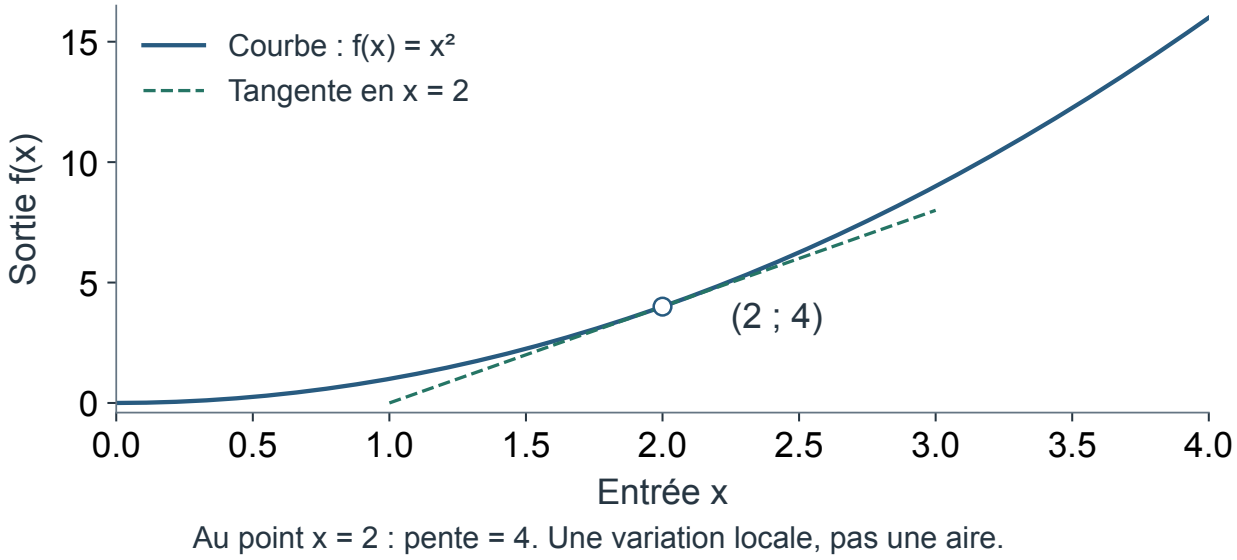
À essayer 4. Pour x = (−3 ; 4), calculez $\|x\|_1$, $\|x\|_2$ et $\|x\|_2^2$.

5. Une dérivée : lire la pente locale

Une courbe peut monter vite, lentement ou redescendre. La dérivée f′(x), lue « f prime de x », décrit sa pente à un endroit précis. Elle compare une petite variation de sortie à une petite variation d'entrée.

$$f'(x) = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}$$

h est un petit déplacement non nul. La flèche h → 0 indique que l'on étudie ce qui se passe quand ce déplacement se rapproche de zéro. On cherche une **limite**, sans remplacer directement h par zéro dans la fraction.



Courbe et tangente : près du point étudié, la droite traduit la variation locale.

Pour f(x) = x² et x = 2, on développe (2 + h)², on soustrait 4, puis on divise par h : le quotient vaut 4 + h. La page suivante déroule ce calcul. Les pas 0,1 et 0,01 donnent 4,1 et 4,01 ; la limite vaut 4. La dérivée s'écrit aussi df/dx.

Pour reprendre cette idée en images : la vidéo de ParaMaths sur la dérivée.

À retenir. Une pente se lit en « unité de sortie par unité d'entrée ». La dérivée d'un volume par rapport au temps donne un débit.

À essayer 5. Pour f(x) = x², la dérivée vaut 2x. Quelle est la pente en x = 3 ? Et en x = −1 ?

Calculer une pente sans sauter une ligne

Pour f(x) = x² au point x = 2, les deux valeurs comparées sont f(2 + h) = (2 + h)² et f(2) = 4. Tant que h est non nul :

$$\frac{(2+h)^2-4}{h} = \frac{4+4h+h^2-4}{h} = \frac{h(4+h)}{h} = 4+h$$

Le quotient tend vers 4 lorsque h tend vers zéro. On a simplifié une expression définie pour h ≠ 0 avant de chercher sa limite. Cela évite la division par zéro.

Quelques règles que l’on réutilise

La dérivée d’une constante vaut 0 ; celle de x vaut 1. Pour un entier n positif, celle de x^n vaut nx^{n-1}. La dérivée d’une somme est la somme des dérivées. Un facteur constant reste devant : la dérivée de $3x^2 + 2x + 7$ vaut $6x + 2$.

Pour multiplier deux fonctions, il faut deux contributions :

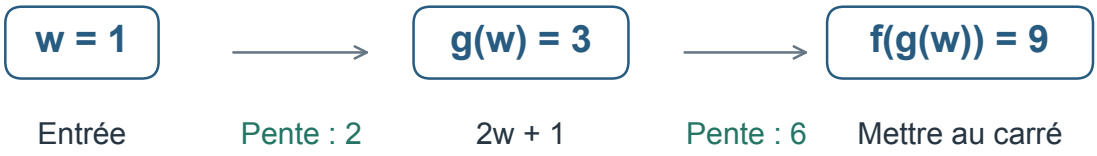
$$(uv)' = u'v + uv' \qquad \left(\frac{u}{v}\right)' = \frac{u'v - uv'}{v^2} \quad (v \neq 0)$$

u et v désignent ici des fonctions de x. Chaque prime indique leur dérivée. Pour u = x et v = x², le produit vaut x³ ; la règle donne 1 × x² + x × 2x = 3x².

À essayer — pente. La dérivée de 2x² + 3x vaut 4x + 3. Au point x = 1, elle vaut 7. Refaites le calcul en séparant les deux termes.

Composition : une variation traverse deux calculs

Un modèle transforme souvent une valeur, puis transforme le résultat. On parle de **composition**. Si g(w) = 2w + 1 et f(z) = z², le calcul f(g(w)) signifie : calculer 2w + 1, puis mettre ce résultat au carré.



Deux calculs successifs : la variation de l’entrée traverse d’abord g, puis f.

La dérivée de la composition multiplie les deux facteurs de variation. La dérivée de f est évaluée à la sortie de g :

$$\frac{d}{dw} f(g(w)) = f'(g(w))\, g'(w) = 2(2w+1) \times 2 = 4(2w+1)$$

En w = 1, g vaut 3. Une petite variation de w est d’abord multipliée par 2, puis par la pente 2 × 3 = 6 : le facteur total vaut 12.

Le même geste dans le gradient

Pour J(w,b) = (2w + b − 5)², posons e = 2w + b − 5. Le carré apporte 2e. En faisant varier w seul, l’expression e apporte 2 ; en faisant varier b seul, elle apporte 1.

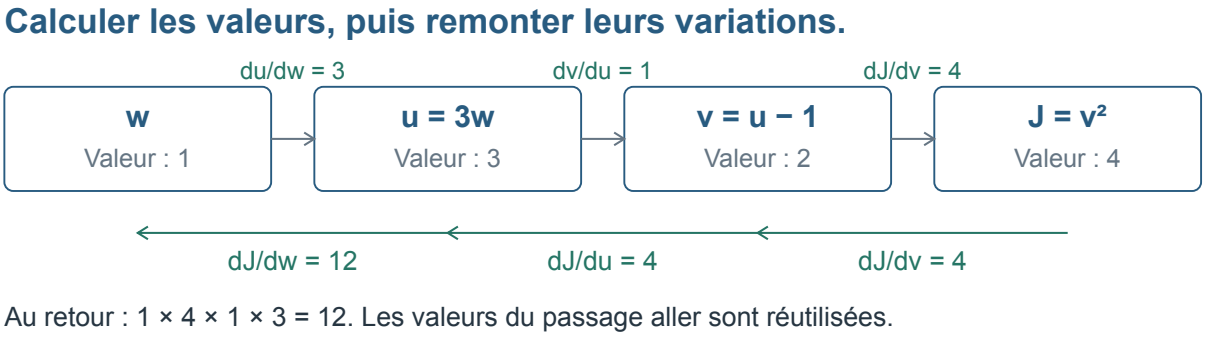
$$\frac{\partial J}{\partial w} = 2e \times 2 = 4e \qquad \frac{\partial J}{\partial b} = 2e \times 1 = 2e$$

À retenir. La rétropropagation réutilise ce geste à travers les couches d’un réseau. Quand plusieurs chemins relient un réglage à la sortie, leurs contributions s’additionnent.

À essayer — composition. Pour J(w) = (3w − 1)², la dérivée vaut 2(3w − 1) × 3. En w = 1, elle vaut 12.

La machine peut suivre les règles de dérivation

Reprenons J(w) = (3w − 1)². Au lieu de traiter toute la formule d'un coup, décomposons-la : u = 3w, v = u − 1, puis J = v². En w = 1, les valeurs successives sont 1, 3, 2 et 4.



Les valeurs vont vers la sortie ; les dérivées remontent le même graphe.

Les dérivées locales sont 3 pour u = 3w, 1 pour v = u − 1 et 2v pour J = v². Ici v vaut 2, donc ce dernier facteur vaut 4.

$$\frac{dJ}{dw} = \frac{dJ}{dv}\frac{dv}{du}\frac{du}{dw} = 4 \times 1 \times 3 = 12$$

La **différentiation automatique** applique ces règles aux opérations du programme. Dans le mode inverse dessiné, elle remonte depuis la sortie et réutilise les valeurs du passage aller. La rétropropagation utilise ce mécanisme dans un réseau neuronal.

Une dérivation symbolique transforme une formule. Une **différence finie** estime la pente à partir de deux valeurs proches. Ici, avec un pas h = 0,01, (J(1 + h) − J(1))/h vaut 12,09. La différentiation automatique compose les règles locales, tout en gardant les limites de précision du calcul numérique.

À retenir. Quand plusieurs chemins contribuent à un paramètre, leurs dérivées s'additionnent. Le panorama de Baydin et ses collègues approfondit les différentes méthodes.

À essayer — dérivée automatique. Reprenez le graphe en w = 0. Que vaut v ? Quel facteur le carré apporte-t-il ? Quelle dérivée obtient-on ? Réponse en fin de guide.

6. Plusieurs réglages : le gradient

Un modèle possède souvent plusieurs paramètres. On rassemble ces réglages dans un vecteur θ, **thêta**. Son coût J(θ) dépend de leurs valeurs.

Une **dérivée partielle** fait varier un paramètre en gardant les autres fixés. Le symbole ∂ se lit « dérivée partielle ». Le **gradient**, noté ∇J, rassemble toutes ces pentes. ∇ porte le nom **nabla**.

$$J(w, b) = (2w + b - 5)^2$$

Posons e = 2w + b − 5. La dérivée du carré est 2e. Une variation de w agit sur e avec un facteur 2 ; une variation de b avec un facteur 1.

$$\frac{\partial J}{\partial w} = 4e \qquad \frac{\partial J}{\partial b} = 2e$$

Pour w = 1 et b = 1, e vaut −2 : le gradient vaut (−8 ; −4). Il indique le sens de plus forte augmentation locale du coût. Pour tenter de diminuer ce coût, on avance dans le sens opposé avec un petit pas η, **êta**.

$$\theta_{\text{nouveau}} = \theta_{\text{actuel}} - \eta \nabla J$$

Avec η = 0,01, on passe à w = 1,08 et b = 1,04. Le coût diminue de 4 à 3,24.

À retenir. Le signe moins donne le sens ; η règle la distance parcourue. Un pas trop grand peut faire augmenter le coût.

À essayer 6. Si une dérivée vaut +6 et que le pas vaut 0,1, de combien la règle modifie-t-elle le paramètre ?

Limites et suites : se rapprocher sans confondre

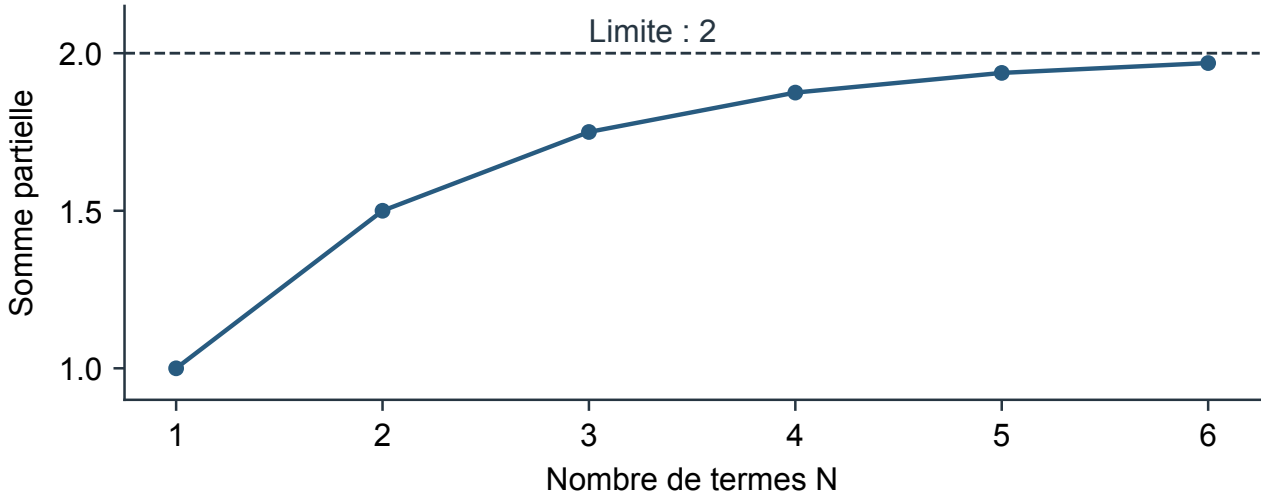
La suite $a_n = 1/2^n$ donne 1, 0,5, 0,25, 0,125… en partant de n = 0. Chaque terme est positif, mais devient aussi petit que l'on veut : sa limite est zéro. Atteindre la limite en un nombre fini d'étapes n'est pas nécessaire.

∞ signifie « sans borne finie ». Ce n'est pas un nombre que l'on remplace dans une fraction. La suite $(-1)^n$ reste bornée entre −1 et 1, mais alterne : elle n'a pas de limite.

Une **suite** énumère des termes ; une **série** les additionne. Avec $0 \le \gamma < 1$:

$$S_N = \sum_{k=0}^{N-1} \gamma^k = \frac{1-\gamma^N}{1-\gamma} \qquad \lim_{N\to\infty} S_N = \frac{1}{1-\gamma}$$

Pour γ = 0,5, les sommes 1 ; 1,5 ; 1,75 ; 1,875 se rapprochent de 2.



Les sommes partielles se rapprochent de deux ; chaque point compte un nombre fini de termes.

Avec γ = 1, on ajoute toujours 1 : la somme croît sans limite. Cela explique pourquoi les récompenses bornées et γ < 1 rendent le retour infini de Bellman fini.

Une relation **récurrente**, comme $a_{n+1} = a_n/2$, calcule le prochain terme à partir du précédent. Une preuve **par récurrence** vérifie un départ puis démontre que, si une propriété est vraie au rang n, elle reste vraie au rang n + 1. Constater quelques termes ne remplace pas cette démonstration.

À essayer — limites. Avec γ = 0,5, calculez la somme des quatre termes d'indices 0 à 3.

Correction — limites. 1 + 0,5 + 0,25 + 0,125 = 1,875. La limite vaut 2 ; elle n'est pas la somme des quatre premiers termes.

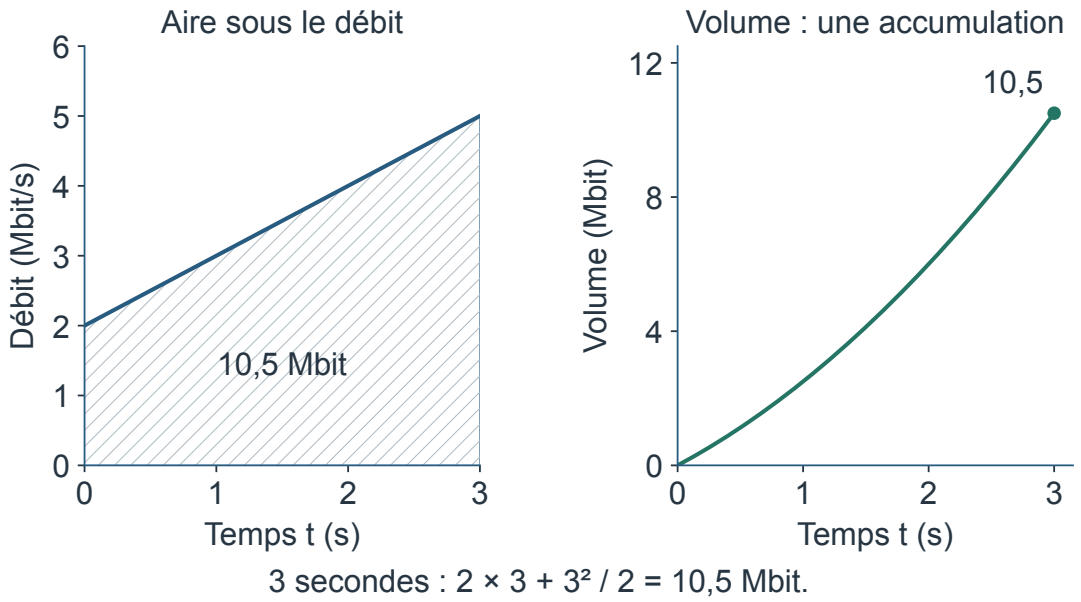
Pour poursuivre : les séries géométriques dans OpenStax.

7. Une intégrale : accumuler de petites contributions

Un débit indique ce qui passe à chaque instant. Une intégrale accumule ces contributions pour retrouver un volume.

$$V(t) = \int_0^t r(u)\,du$$

∫ est le signe de l'intégrale. Les bornes 0 et t encadrent la période. r(u) désigne le débit à un instant intermédiaire u ; du représente un très petit intervalle de temps.



L'aire sous le débit donne le volume reçu ; les deux graphes décrivent le même transfert.

Pour r(u) = 2 + u Mbit/s, avec u en secondes entre 0 et 3, le volume vaut 2t + t²/2. À t = 3, on trouve 6 + 4,5 = 10,5 Mbit.

À retenir. Somme et intégrale partagent l'idée d'accumulation. Une somme compte des contributions distinctes ; une intégrale traite une variation continue.

À essayer 7. À débit constant de 4 Mbit/s pendant 3 secondes, quel volume reçoit-on ? Quelle aire représente ce calcul ?

Pour voir cette accumulation autrement : « Une bille qui roule suffit pour comprendre les intégrales », de ParaMaths.

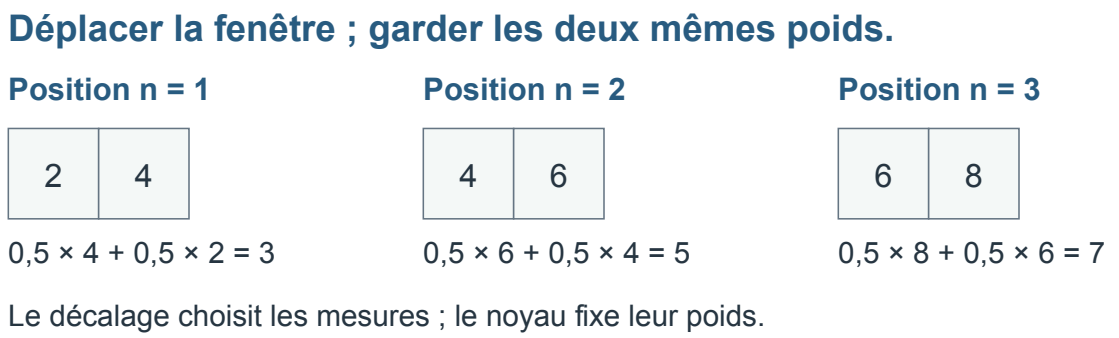
8. Convolution : faire glisser le même filtre

Pour lisser une suite de mesures, on peut faire la moyenne de deux valeurs voisines, puis déplacer ce petit calcul. Les coefficients du filtre, appelé **noyau**, restent les mêmes à chaque position.

$$y[n] = (x * h)[n] = \sum_{k=0}^{m-1} h[k]\, x[n-k]$$

Les crochets repèrent une valeur de la suite. Ici, n est la position de sortie ; k parcourt les m coefficients du noyau. x[n − k] choisit une mesure décalée. Le signe ∗ désigne la convolution, pas une multiplication ordinaire.

Prenons x = (2 ; 4 ; 6 ; 8), avec x[0] = 2, et h = (0,5 ; 0,5). À la position n = 2 : y[2] = 0,5 × 6 + 0,5 × 4 = 5.



Trois positions, le même noyau : chaque sortie combine deux mesures voisines.

Retrouver la même idée en temps continu

$$(x * h)(t) = \int_{-\infty}^{+\infty} h(u)\, x(t-u)\, du$$

La somme devient une intégrale ; u joue le rôle du décalage. Les bornes −∞ et +∞ couvrent tous les décalages réels. Cette écriture suppose que l'intégrale existe.

À retenir. La règle ne change pas quand la fenêtre se déplace. Aux bords, il faut préciser les valeurs utilisées : ici, x vaut zéro en dehors des quatre mesures.

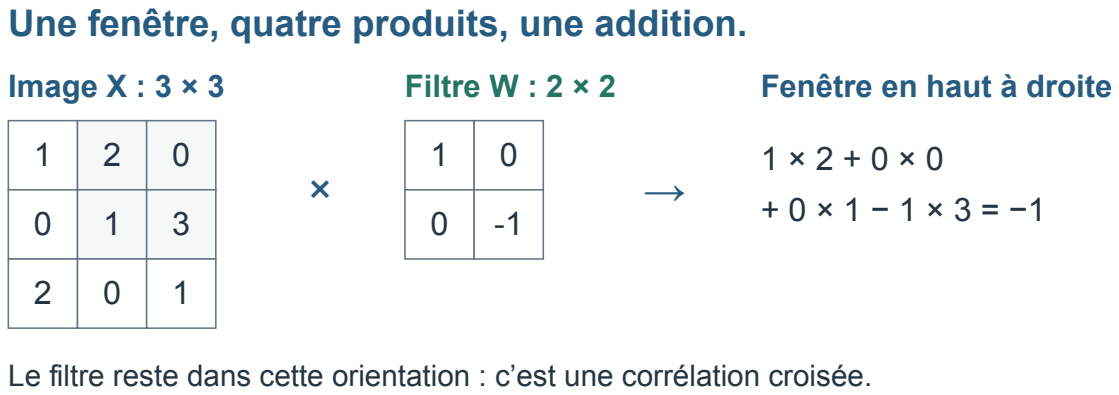
À essayer 8. Avec ce prolongement par zéro, calculez y[0] et y[4]. Pourquoi ne sont-elles pas des moyennes de deux mesures disponibles ?

9. Des fenêtres d’image aux CNN

Une image en niveaux de gris est un tableau X. Un filtre W parcourt de petites fenêtres : on multiplie les valeurs qui se correspondent, puis on additionne. Dans cet exemple, le filtre a deux lignes et deux colonnes.

$$Y[i,j] = \sum_{a=0}^{1} \sum_{b=0}^{1} W[a,b]\, X[i+a, j+b]$$

i et j situent le coin de la fenêtre ; a et b repèrent une case du filtre. Les deux Σ demandent d’additionner les colonnes de chaque ligne, puis les lignes. On obtient un nombre par fenêtre.



La fenêtre en haut à droite donne −1 : multiplier case par case, puis additionner.

Avec un **pas** (*stride*) de 1 et sans ajout au bord, les quatre fenêtres donnent une sortie 2 × 2. Le **padding** ajoute des valeurs au bord, souvent des zéros. Pas et padding déterminent les fenêtres calculées et les dimensions de sortie.

Un **CNN** (*Convolutional Neural Network*, réseau neuronal convolutif) apprend les coefficients des filtres par rétropropagation. Chaque filtre réutilise ses poids dans l’image ; avec plusieurs canaux, leurs contributions s’additionnent.

À retenir. Ce calcul est une **corrélation croisée**. La convolution mathématique retourne le noyau dans les deux directions. Les couches des CNN portent couramment le nom « convolution », même lorsqu’elles calculent cette corrélation croisée.

À essayer 9. Retrouvez les quatre sorties avec le filtre dessiné. Quelle taille obtient-on avec un pas de 2, sans padding ?

Pour poursuivre : Dive into Deep Learning, convolutions pour les images et pas et padding.

10. Exponentielle et logarithme : deux trajets inverses

L'exponentielle e^x transforme une somme en produit : $e^{(a+b)} = e^a \times e^b$. Le nombre e vaut environ 2,718. Pour tout réel x, e^x est positif.

Le logarithme naturel, noté ln, fait le trajet inverse : $\ln(e^x) = x$. Ainsi, $e^0 = 1$ et $\ln(1) = 0$. Le logarithme naturel demande une entrée strictement positive.

Pourquoi les probabilités passent par un logarithme

Si le modèle attribue une probabilité p à la bonne réponse, la perte $-\ln(p)$ pénalise une faible probabilité. Pour p = 0,8, elle vaut environ 0,223 ; pour p = 0,1, environ 2,303.

$$L = -\ln(p)$$

Le signe moins transforme le logarithme, négatif pour $0 < p < 1$, en coût positif. Une probabilité proche de 1 donne un coût proche de zéro.

Lire une softmax

La softmax transforme des scores z en poids positifs dont la somme vaut 1 :

$$p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$$

k désigne la classe dont on veut le poids ; j parcourt toutes les classes du dénominateur. Des scores égaux donnent des poids égaux. Ces poids ne sont pas automatiquement des probabilités bien calibrées en situation réelle.

À essayer 10. Deux scores valent 0 et 0. Quels poids la softmax produit-elle ?

La température d’un LLM : changer le tirage

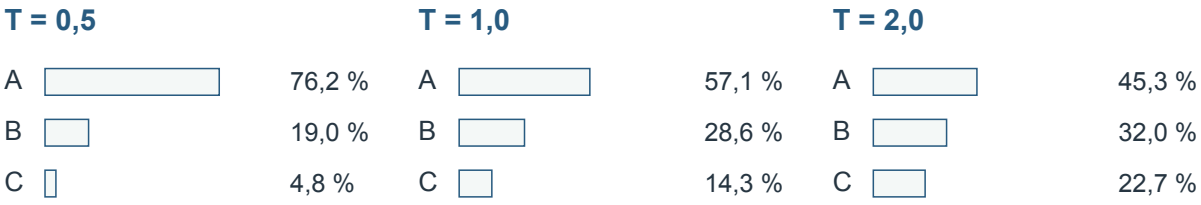
Pour poursuivre un texte, un LLM calcule des scores pour les prochains **jetons**, des mots ou fragments de mots. Ces scores de sortie s’appellent des **logits**. La softmax les transforme en probabilités de tirage.

Avec un tirage aléatoire, la **température** T > 0 divise les scores avant la softmax :

$$p_i(T) = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$$

i repère le candidat dont on lit la probabilité ; j parcourt tous les candidats. Prenons trois jetons A, B et C, avec les scores (ln 4 ; ln 2 ; 0). Pour T = 1, les exponentielles valent (4 ; 2 ; 1). Leur somme vaut 7 : les probabilités sont (4/7 ; 2/7 ; 1/7).

La température change la répartition du tirage.



Mêmes scores : (ln 4 ; ln 2 ; 0). A, B et C désignent trois jetons possibles.

À scores identiques, une petite température concentre les probabilités et une grande température les rapproche.

Pour T = 0,5, les scores doublent. Les exponentielles valent (16 ; 4 ; 1), et les probabilités (16/21 ; 4/21 ; 1/21). Le jeton A devient plus fréquent dans les tirages. L’exemple ne comporte aucun autre filtrage des candidats.

À retenir. La température règle la répartition du tirage. Elle ne modifie pas les paramètres appris et ne garantit pas la vérité du texte. En choix glouton, on prend directement le jeton au score maximal. La documentation de génération décrit ces réglages.

À essayer — température. Avec deux scores égaux à zéro, que deviennent les probabilités pour T = 0,5 puis T = 2 ? Réponse en fin de guide.

Logarithmes : préciser la base et les unités

$\log_2(8) = 3$ répond à la question « quelle puissance de 2 donne 8 ? ». $\log_{10}(1000) = 3$ répond à la même question avec la base 10. ln utilise la base e, environ 2,718. Pour changer de base : $\log_2(x) = \ln(x)/\ln(2)$, pour x positif.

Shannon : lire le rapport avant de calculer

Dans la formule ci-dessous, B est une largeur de bande en hertz ; S/N est un rapport de puissances **en valeurs linéaires**. Le logarithme en base 2 conduit à une capacité C en bits par seconde, dans le modèle de canal considéré.

$$C = B\log_2(1 + S/N)$$

Avec B = 1 MHz, soit un million de hertz, et S/N = 10, on calcule $\log_2(11) \approx 3{,}46$. La capacité vaut donc environ 3,46 Mbit/s.

Décibels : comprimer l’échelle des rapports

$$D = 10\log_{10}(r) \qquad r = 10^{D/10}$$

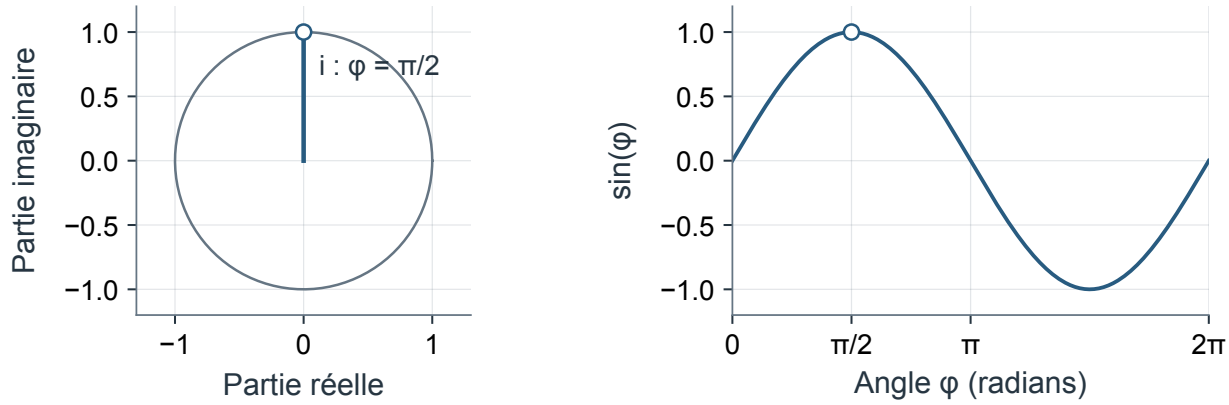
r désigne un rapport de puissances positif. Un rapport 1 donne 0 dB ; 10 donne 10 dB ; 100 donne 20 dB. Un rapport 0,1 donne −10 dB. Ajouter 10 dB multiplie la puissance relative par dix. Le dBm mesure, lui, une puissance rapportée à 1 mW.

À retenir. Pour insérer un SNR de 20 dB dans Shannon, on le convertit d’abord : S/N = 100. La règle $20\log_{10}$ concerne des rapports d’amplitudes lorsque la puissance est proportionnelle au carré de l’amplitude.

À essayer — radio. Pour B = 1 MHz et SNR = 0 dB, le rapport linéaire vaut 1 : C = 1 Mbit/s.

Sinus, phase et nombres complexes : deux coordonnées

Une oscillation répète un mouvement. Dans A sin(2πft + φ), A règle l'amplitude, f le nombre de cycles par seconde, t le temps et φ, **phi**, le décalage de phase. π, **pi**, est ici le nombre constant qui vaut environ 3,1416. L'angle s'exprime en **radians** : 2π radians font un tour, soit 360 degrés. À 2 Hz, un cycle dure 1/2 seconde.



Un quart de tour sur le cercle correspond au sommet du sinus. La phase décale le point de départ.

Un **nombre complexe** z = a + ib rassemble deux coordonnées réelles. i vérifie $i^2 = -1$; dans les textes de radio, j peut remplacer i pour éviter une confusion avec un courant. Ici i n'est pas un indice.

$$z = a + ib \qquad |z| = \sqrt{a^2 + b^2} \qquad e^{i\phi} = \cos\phi + i\sin\phi$$

Pour z = 3 + 4i, le module vaut 5. Le conjugué $\bar{z} = 3 - 4i$ change le signe de la seconde coordonnée ; $z\bar{z} = 25$. La formule d'Euler décrit un point du cercle unité : l'angle φ donne sa direction. Multiplier par $e^{i\varphi}$ fait tourner un nombre complexe sans changer son module.

Dans les communications radio, ces deux coordonnées permettent de représenter une amplitude et une phase. Pour une matrice complexe H, H^H signifie **transposée conjuguée** : échanger lignes et colonnes, puis conjuguer chaque coefficient. Pour une matrice réelle, cette opération revient à la transposée $H^\top$.

À essayer — complexe. Pour z = 1 + i, le conjugué vaut 1 − i et $|z|^2$ vaut 2. Le module vaut donc √2.

Taylor : approcher près d’un point

Une tangente remplace une courbe par une droite près du point étudié. Si l’on connaît aussi sa courbure, on peut ajouter un terme de degré deux. La notation f″ désigne la dérivée de la dérivée.

$$f(a+h) \approx f(a) + hf'(a) + \frac{h^2}{2}f''(a)$$

a est le point de départ ; h le déplacement. Il faut une fonction assez régulière près de a ; la qualité dépend de la taille du déplacement et des termes négligés. Le symbole ≈ indique une approximation.

Pour f(x) = x², f′(x) = 2x et f″(x) = 2. Au point a = 2, on trouve 4 + 4h + h². Pour ce polynôme, cette expression est exacte : aucun terme ne manque. La tangente seule, 4 + 4h, oublie h².

Pour e^h près de zéro, les trois premiers termes donnent 1 + h + h²/2. En h = 0,1, ils donnent 1,105 ; exp(0,1) vaut environ 1,10517. En h = 1, ils donnent 2,5, contre environ 2,71828 : éloigner le point augmente ici l’erreur.

À retenir. Taylor approxime autour d’un point ; Fourier décompose selon des fréquences. Une formule locale ne devient pas exacte partout parce que l’on ajoute quelques termes. Les coefficients 1/n! divisent par la factorielle : 3! = 1 × 2 × 3 = 6.

À essayer — taylor. Pour x² près de a = 2 et h = 0,2, quelle erreur la tangente seule commet-elle, en valeur absolue ?

Correction — taylor. La valeur exacte vaut 2,2² = 4,84 ; la tangente donne 4 + 4 × 0,2 = 4,8. L’erreur vaut 0,04, le terme h² omis.

Des angles pour trouver un point

La tangente d'un angle, notée tan, est le rapport sin/cos lorsque le cosinus n'est pas nul. Dans un triangle rectangle, elle donne le rapport hauteur/distance horizontale.

Deux observateurs sont en A = (0, 0) et B = (10, 0), en mètres. Ils visent un point P au-dessus de la base AB. Depuis A, l'angle α, **alpha**, est mesuré vers B ; depuis B, β, **bêta**, est mesuré vers A. Les deux hauteurs doivent être les mêmes :

$$y = x\tan\alpha = (10 - x)\tan\beta$$

Développer, puis rassembler les termes en x donne x(tan α + tan β) = 10 tan β. Ainsi :

$$x = \frac{10\tan\beta}{\tan\alpha + \tan\beta} \qquad y = x\tan\alpha$$

Avec tan α = 4/3 et tan β = 4/7, le calcul donne x = 3 et y = 4. C'est une triangulation. Les angles correspondants sont environ 53,13° et 29,74° ; les angles arrondis donnent une position approchée.

La **trilatération** emploie des distances. Pour A = (0, 0), B = (10, 0), C = (0, 10), les trois distances au carré valent 25, 65 et 45. Soustraire la première équation de cercle des deux autres donne −20x + 100 = 40 et −20y + 100 = 20. On retrouve (3, 4).

À essayer — localisation. Pourquoi les distances depuis A et B seulement ne permettent-elles pas de choisir entre (3, 4) et (3, −4) ?

Correction — localisation. La symétrie par rapport à AB conserve ces deux distances. La distance depuis C change : √45 pour (3, 4), mais √205 pour (3, −4). Elle permet de les distinguer.

GNSS : quatre inconnues dans un même calcul

Le récepteur cherche ses trois coordonnées et le retard de son horloge. Pour garder toutes les inconnues en mètres, on écrit b = c δt : c est la vitesse de la lumière et δt le retard en secondes. Après les corrections de propagation, le modèle simplifié d'une mesure est :

$$\rho_i = \sqrt{(x - x_i)^2 + (y - y_i)^2 + (z - z_i)^2} + b$$

L'indice i repère un satellite ; ses coordonnées sont prises au moment de l'émission dans un repère compatible avec celui du récepteur. ρ_i, **rhô indice i**, est la pseudodistance corrigée. À une position approchée (x_0, y_0, z_0), la distance calculée est d_i. La dérivée par rapport à x vaut $(x_0 - x_i)/d_i$; de même pour y et z. La dérivée par rapport à b vaut 1.

Ces quatre coefficients forment une ligne de la matrice H. Le vecteur e contient les mesures moins les valeurs prévues. Une petite correction Δp = (Δx, Δy, Δz, Δb) vérifie alors :

$$H\Delta p \approx e$$

Il s'agit de Taylor au premier ordre, appliqué à chaque mesure. On résout ce système, on ajoute la correction et on recommence. Avec davantage de mesures, on minimise la somme des carrés des résidus ; une factorisation QR évite de calculer une inverse explicitement. Elle réécrit H en un produit : Q porte des colonnes orthonormales, R une matrice triangulaire, qui permet de résoudre par substitutions.

À essayer — horloge. Que représente un décalage de 1 microseconde ?

Correction — horloge. 1 microseconde vaut 10^{-6} s. Avec c ≈ 3×10^8 m/s, b ≈ 300 m. Oublier l'horloge déplace l'interprétation de toutes les distances.

Il faut une matrice H de rang quatre pour déterminer les quatre corrections. Une mauvaise géométrie amplifie les erreurs. La dérivation complète de l'ESA) permet de poursuivre ce calcul.

Kepler : résoudre une équation que l'on ne peut pas isoler

Pour une ellipse d'excentricité e, avec $0 \le e < 1$, l'angle auxiliaire E et l'anomalie moyenne M vérifient :

$$E - e\sin E = M$$

Les angles sont en radians. E ne se laisse pas isoler par les opérations usuelles. On cherche le zéro de $f(E) = E - e \sin E - M$. La méthode de Newton utilise la pente $f'(E) = 1 - e \cos E$:

$$E_{k+1} = E_k - \frac{E_k - e\sin E_k - M}{1 - e\cos E_k}$$

Le k désigne une itération. Le dénominateur reste positif pour $e < 1$, mais le choix de départ et l'arrêt du calcul comptent. Avec $e = 0{,}1$, $M = 0{,}5$ et $E_0 = 0{,}5$, on obtient $E_1 \approx 0{,}552555$ puis $E_2 \approx 0{,}552480$. Réinjecter cette valeur donne $E - 0{,}1 \sin E \approx 0{,}5$. Pour un calcul général, on fixe une tolérance, un nombre maximal d'itérations et une méthode de secours si nécessaire.

Avec le demi-grand axe a, les coordonnées dans le plan de l'ellipse sont :

$$x_o = a(\cos E - e) \qquad y_o = a\sqrt{1 - e^2}\sin E$$

À essayer — orbite circulaire. Que devient le calcul lorsque e = 0 ?

Correction — orbite circulaire. E = M ; les coordonnées deviennent (a cos M, a sin M). Leur distance au centre vaut toujours a.

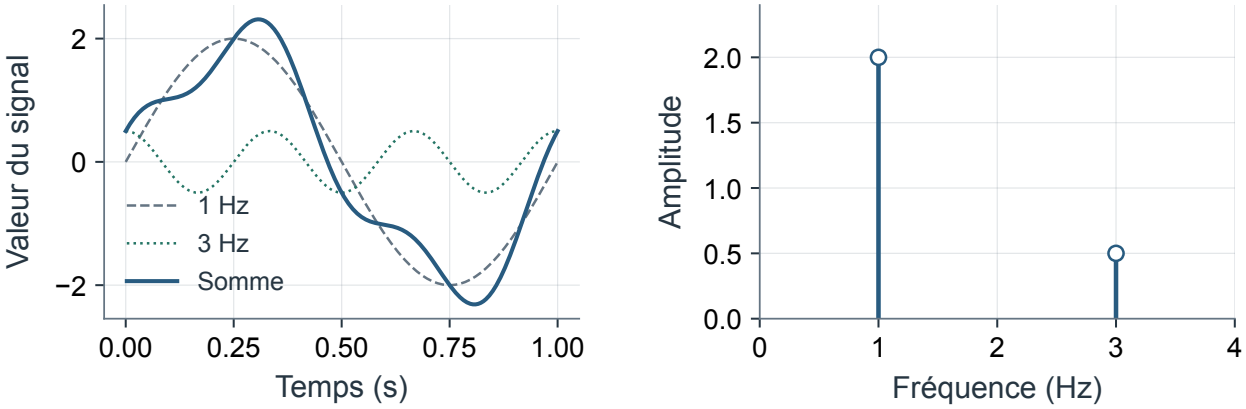
Le livre reprend la conversion du mouvement moyen en période et les rotations du plan orbital. Un **TLE** contient des éléments moyens pour **SGP4** : ces formules à deux corps servent à comprendre le mécanisme, puis SGP4 sert à propager les éléments selon leur modèle. La documentation CelesTrak fournit des cas de contrôle.

Fourier : lire les fréquences cachées dans une courbe

Une courbe compliquée peut additionner deux oscillations simples. Reprenons l'exemple du livre, avec t en secondes :

$$f(t) = 2\sin(2\pi t) + 0{,}5\cos(6\pi t)$$

Le premier terme effectue un cycle par seconde : 1 Hz, avec une amplitude 2. Comme 6πt = 2π × 3t, le second effectue trois cycles par seconde : 3 Hz, avec une amplitude 0,5. La courbe résultante additionne leurs valeurs à chaque instant.



À gauche, les deux oscillations et leur somme ; à droite, leurs deux amplitudes dans une représentation unilatérale.

Fourier change la question : au lieu de demander la valeur à chaque instant, on cherche les fréquences, amplitudes et phases qui composent le signal. Un spectre d'amplitude seul ne montre pas les phases.

Lire la transformée sans calculer toute l'intégrale

$$\hat{f}(\nu) = \int_{-\infty}^{+\infty} f(t) e^{-2\pi i \nu t}\, dt$$

ν, **nu**, est la fréquence étudiée ; le chapeau signale la représentation transformée. Le facteur complexe fournit une oscillation de référence ; l'intégrale accumule sa comparaison avec le signal. Il faut que l'intégrale existe. Notre exemple périodique se décrit par une **série de Fourier**, une somme de fréquences discrètes.

À retenir. La convolution avec un filtre devient une multiplication dans le domaine fréquentiel, avec cette convention de transformée : le calcul se simplifie.

Ensembles et intervalles : lire les conditions

Une formule précise souvent les valeurs autorisées. Dans $x \in [0,1]$, le nombre x appartient à l'intervalle de zéro à un, bornes comprises. Dans $x \in]0,1[$, les deux bornes sont exclues. L'écriture (0,1), courante en anglais, désigne aussi cet intervalle ouvert.

Pour $a \le b$, $[a,b]$ inclut les deux bornes ; $]a,b]$ exclut seulement a. Le signe $<$ est strict ; $\le$ autorise l'égalité. Multiplier une inégalité par un nombre négatif inverse son sens : $x < 2$ donne $-x > -2$.

Dans une observation, A peut être l'ensemble des cas avec alarme, B celui des cas avec incident. $A \cap B$ contient les deux à la fois ; $A \cup B$ contient au moins l'un des deux. Le complément A^c contient les cas sans alarme.

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Soustraire l'intersection évite de compter deux fois les cas communs. Si $P(A) = 0{,}20$, $P(B) = 0{,}08$ et $P(A \cap B) = 0{,}06$, la probabilité d'au moins un événement vaut 0,22.

Une **indicatrice** vaut 1 si une condition est satisfaite, 0 sinon : $\mathbb{1}\{x > 2\}$ vaut 0 en $x = 2$ et 1 en $x = 3$. Additionner des indicatrices compte les cas qui satisfont la condition.

À essayer — conditions. Pour les délais (1 ; 2 ; 3 ; 4) ms, combien appartiennent à $]1,3]$?

Correction — conditions. Deux : 2 et 3. La borne 1 est exclue et la borne 3 incluse. La somme des quatre indicatrices vaut 2.

Modulo : compter sur une boucle

Un compteur de trois bits prend les valeurs de 0 à 7, puis revient à zéro. Ajouter trois à six donne neuf dans les entiers ; sur ce compteur, le résultat est un.

$$9 = 1 \times 8 + 1, \qquad 9 \bmod 8 = 1, \qquad 9 \equiv 1 \ (\mathrm{mod}\ 8).$$

Le modulo donne le reste de la division par un entier positif. Le signe ≡ indique ici une **congruence** : deux entiers ont le même reste, donc leur différence est un multiple de huit. Il ne signifie pas qu'ils sont égaux comme entiers.

L'ensemble $\mathbb{Z}_8$ regroupe les huit classes de restes 0, …, 7. On y additionne et multiplie en gardant le reste. Avec le représentant de 0 à 7, $-1 \bmod 8$ vaut 7.

On ne peut pas toujours diviser : modulo 8, aucun entier z ne vérifie $2z \equiv 1$. Le nombre 3 possède en revanche un inverse, car $3 \times 3 \equiv 1$. Une opération valable dans les réels ne se transporte donc pas automatiquement dans $\mathbb{Z}_8$.

À retenir. Le même reste ne révèle pas combien de tours le compteur a fait. Dans les protocoles, comparer des séquences exige aussi une fenêtre et un contexte ; dans le chiffrement homomorphe, les bornes évitent de confondre une somme entière avec son reste.

À essayer — modulo. Un compteur modulo 8 vaut 7 ; on lui ajoute 4. Quel reste obtient-on ?

Correction — modulo. 7 + 4 = 11 = 1 × 8 + 3 : le résultat vaut 3. Ce n'est pas l'entier 11.

11. « B sachant A » : changer le groupe que l’on observe

Parmi 100 situations, 20 déclenchent une alarme A. Huit présentent un incident B. Six présentent les deux.

Pour calculer P(B | A), on regarde uniquement les 20 situations avec alarme. Six présentent un incident : la probabilité vaut 6/20 = 0,30.

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)}$$

La barre verticale se lit **sachant**. Le symbole ∩ se lit **et** : A ∩ B signifie que les deux événements se produisent. La formule suppose P(A) > 0.

Dans l’autre sens, P(A | B) vaut 6/8 = 0,75. Le groupe de départ a changé : parmi les huit incidents, six produisent une alarme.

Bayes relie les deux lectures

$$P(B \mid A) = \frac{P(A \mid B)P(B)}{P(A)}$$

Ici, 0,75 × 0,08 / 0,20 = 0,30. P(B) est la fréquence des incidents avant de regarder l’alarme ; P(B | A) intègre cette information supplémentaire.

À retenir. Lire « parmi les cas où A est vrai » aide à choisir le dénominateur.

À essayer 11. Si 10 alarmes supplémentaires sans incident s’ajoutent, combien vaut désormais P(B | A) ? Le nombre d’incidents a-t-il changé ?

Compter les possibilités et choisir une loi

Trois transmissions indépendantes — la perte de l'une ne change pas la probabilité de perte des autres — ont chacune une probabilité de perte p = 0,5. Pour perdre exactement deux transmissions, il existe trois choix : les positions (1,2), (1,3) ou (2,3). Chacun vaut $0{,}5^3$; le total vaut 3/8.

Le nombre de façons de choisir k positions parmi n, sans tenir compte de leur ordre, est un **coefficient binomial** :

$$\binom{n}{k} = \frac{n!}{k!\,(n-k)!}, \qquad P(K = k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

n! multiplie les entiers de 1 à n ; 0! = 1. Ici n = 3 et k = 2, donc 3!/(2!1!) = 3. K suit une **loi binomiale** si le nombre d'essais est fixé, les essais sont indépendants et leur probabilité p reste la même. Un seul essai de résultat 0 ou 1 suit une loi de Bernoulli.

Pour compter des arrivées sur une durée t, un modèle de **Poisson** peut convenir si les arrivées ont un taux constant λ et des accroissements indépendants :

$$P(N_t = k) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}.$$

λ est un nombre d'arrivées par unité de temps ; λt est sans unité. Avec λ = 2 par seconde et t = 0,5 seconde, la probabilité d'aucune arrivée vaut e^{-1}, environ 0,368.

À retenir. Une loi se choisit selon le mécanisme et ses hypothèses. Des pertes en rafales ne sont pas des essais indépendants ; une courbe de délais n'est pas nécessairement normale parce qu'elle semble arrondie.

À essayer — lois. Quatre transmissions indépendantes ont p = 0,5. Quelle est la probabilité d'exactement deux pertes ?

Correction — lois. Il existe 4!/(2!2!) = 6 choix ; chacun vaut $0{,}5^4 = 1/16$. La probabilité vaut 6/16 = 0,375.

12. Espérance, variance et incertitude

Une **espérance** est une moyenne pondérée par les probabilités. Le symbole E se lit « espérance ». Si X vaut 2 avec probabilité 1/4 et 6 avec probabilité 3/4, sa valeur moyenne attendue est 5.

$$\mathbb{E}[X] = \frac{1}{4} \times 2 + \frac{3}{4} \times 6 = 5$$

Une moyenne observée sur quelques cas est une estimation de l'espérance. Ces deux objets se rapprochent dans certaines conditions ; ils ne sont pas identiques pour un échantillon quelconque.

La **variance** mesure la dispersion autour de la moyenne μ, **mu** :

$$\mathrm{Var}(X) = \mathbb{E}[(X - \mu)^2] \qquad \sigma = \sqrt{\mathrm{Var}(X)}$$

σ, **sigma minuscule**, est l'écart-type. Il retrouve l'unité de X : une variance de délais s'exprime en secondes au carré ; leur écart-type s'exprime en secondes.

Pour les trois valeurs 2, 4 et 6 considérées avec des poids égaux, la moyenne vaut 4 et la variance vaut (4 + 0 + 4)/3 = 8/3. Pour estimer une variance de population à partir d'un échantillon, on rencontre aussi une division par n − 1 : il faut lire la définition choisie.

À retenir. Σ additionne ; σ mesure ici une dispersion. Une même lettre peut avoir un autre rôle dans un autre chapitre.

À essayer 12. Deux valeurs 3 et 3 ont-elles une variance nulle ou positive ?

Normaliser : retrouver des échelles comparables

Deux observations diffèrent de 20 ms en délai et de 10 points de pourcentage en charge. Additionner les carrés des nombres bruts donne $20^2 + 10^2 = 500$. En secondes, le même écart de délai vaut 0,020 : le calcul donne $0{,}020^2 + 10^2 = 100{,}0004$. Le poids relatif des variables dépend alors du choix d'unité.

Les unités changent le poids des nombres bruts.

Deux observations : écart de délai de 20 ms et écart de charge de 10 points.

Unité du délai	Écart de délai	Écart de charge	Carrés bruts additionnés
Millisecondes	20	10	400 + 100 = 500
Secondes	0,020	10	0,0004 + 100

Les mesures restent identiques ; seul le poids relatif des deux variables change.

L'addition brute change lorsqu'on passe des millisecondes aux secondes, alors que les observations restent les mêmes.

Le **centrage-réduction** soustrait une moyenne μ, puis divise par un écart-type σ non nul. On le nomme aussi **standardisation** ; c'est une des façons de normaliser les données.

$$\widetilde{x} = \frac{x - \mu}{\sigma}$$

Le tilde repère la valeur transformée. Pour les délais (10 ; 10 ; 30 ; 30) ms, μ vaut 20 ms. La moyenne des quatre carrés des écarts vaut 100 ms², donc σ vaut 10 ms. Les valeurs transformées sont (−1 ; −1 ; 1 ; 1).

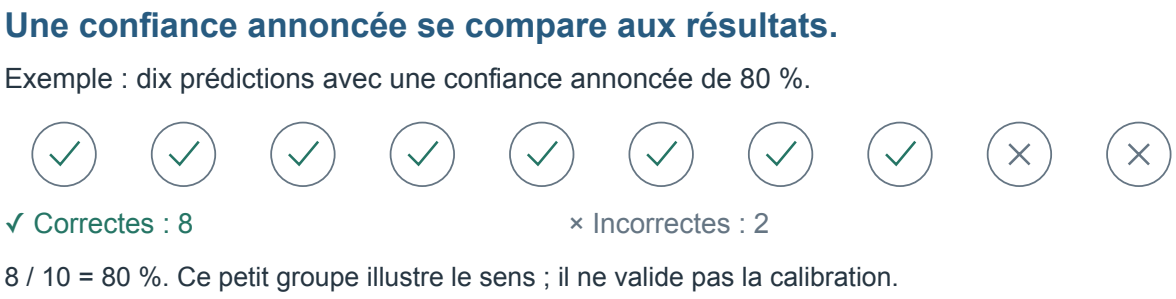
En secondes, μ = 0,020 et σ = 0,010. Pour le premier délai : (0,010 − 0,020)/0,010 = −1. Le résultat est sans unité et reste identique.

À retenir. Une échelle adaptée empêche une unité de dominer le calcul. L'importance métier des variables reste à choisir. μ et σ sont calculés sur l'entraînement puis conservés pour la suite ; une variable constante demande un traitement adapté. StandardScaler décrit ce calcul.

À essayer — normalisation. Avec μ = 20 ms et σ = 10 ms, transformez un délai de 25 ms. Retrouvez le résultat en secondes. Réponse en fin de guide.

Une confiance de 80 % : regarder les résultats

Un modèle classe des observations et annonce une confiance de 80 % pour chaque prédiction. Sur de nombreux cas comparables, cette annonce devrait correspondre à environ huit prédictions correctes sur dix.



Huit prédictions correctes parmi dix donnent une fréquence de succès de 80 %.

$$\text{fréquence de succès} = \frac{\text{prédictions correctes}}{\text{prédictions examinées}} = \frac{8}{10} = 0{,}8$$

La **calibration** compare cette fréquence à la confiance annoncée. Si seulement 60 % d'un grand ensemble de prédictions annoncées autour de 80 % sont correctes, le modèle est trop confiant dans cette plage.

Le dessin illustre le sens du calcul. Dix cas ne suffisent pas à vérifier une calibration : il faut davantage de données nouvelles et plusieurs plages de confiance. La calibration se règle sur des données réservées, puis s'évalue sur un test distinct.

À retenir. L'exactitude compte les prédictions correctes ; la calibration vérifie leur confiance annoncée. Même bien calibrée, une prédiction particulière peut être fausse. La documentation sur la calibration présente des courbes pour comparer annonces et résultats.

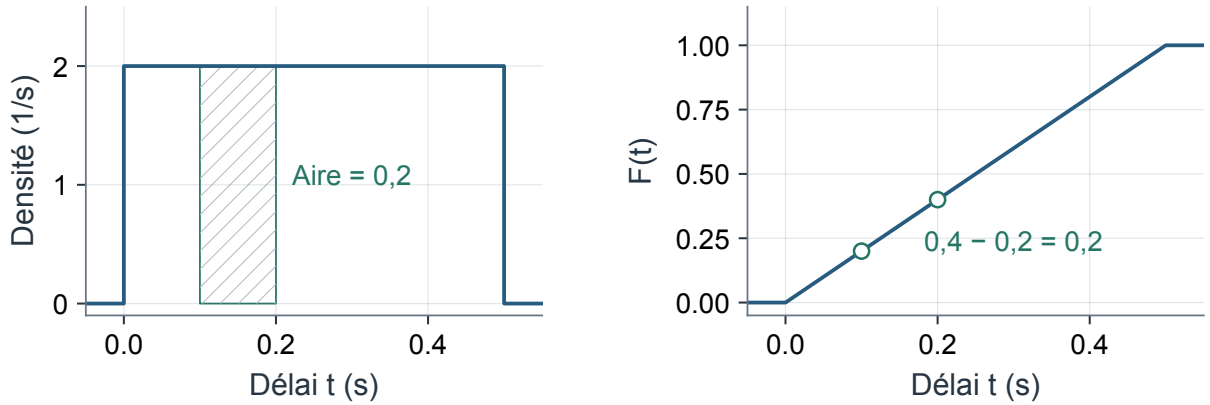
À essayer — confiance. Un modèle annonce environ 90 % pour 100 prédictions comparables ; 70 sont correctes. Quel est l'écart entre la confiance annoncée et la fréquence observée ? Réponse en fin de guide.

Densité et répartition : une aire devient une probabilité

Un délai T varie uniformément entre 0 et 0,5 seconde. Tous les intervalles de même longueur dans cette plage ont la même probabilité. Sa **densité** vaut 2 par seconde dans cette plage, et zéro ailleurs.

$$P(0{,}1 \le T \le 0{,}2) = \int_{0{,}1}^{0{,}2} 2\,dt = 2 \times (0{,}2 - 0{,}1) = 0{,}2$$

La hauteur 2 n’est pas une probabilité : c’est une densité. L’aire du rectangle vaut 0,2, soit 20 %. L’aire de toute la plage vaut 2 × 0,5 = 1. Une densité peut dépasser 1 ; la probabilité reste comprise entre 0 et 1.



Une densité donne la hauteur ; la fonction de répartition donne l’aire déjà accumulée.

La **fonction de répartition** F(t) = P(T ≤ t) cumule la probabilité jusqu’à t. Ici F(0,2) = 0,4 et F(0,1) = 0,2. Leur différence redonne la probabilité de l’intervalle. F vaut 0 avant 0, croît comme 2t entre 0 et 0,5, puis vaut 1.

Pour une variable ayant une densité, la probabilité d’une valeur exacte est nulle : P(T = 0,2) = 0. Un appareil arrondit ses mesures ; afficher 0,2 seconde couvre en pratique une petite plage.

À essayer — densité. Entre 0,2 et 0,4 seconde, la probabilité vaut 2 × 0,2 = 0,4. Retrouvez-la aussi en soustrayant F(0,2) de F(0,4).

Indépendance, produit et vraisemblance

La probabilité conditionnelle P(B | A) observe B parmi les cas où A se produit. Si cette information ne change pas la probabilité de B, les deux événements sont **indépendants**. Lorsque P(A) > 0 :

$$P(B \mid A) = P(B) \quad \Longleftrightarrow \quad P(A \cap B) = P(A)P(B)$$

∩ se lit « et » : les deux événements se produisent. Deux pièces équilibrées lancées indépendamment donnent deux faces avec une probabilité 1/2 × 1/2 = 1/4. Deux équipements alimentés par le même circuit peuvent au contraire tomber en panne ensemble : multiplier leurs probabilités de panne demande une justification.

Le produit compact, noté ∏

La lettre grecque Π, **pi majuscule**, rassemble des multiplications. Pour trois nombres :

$$\prod_{i=1}^{3} p_i = p_1 p_2 p_3$$

Σ additionne ; ∏ multiplie. Dans un modèle, la **vraisemblance** L(θ) mesure à quel point les observations sont compatibles avec le réglage θ. Si elles sont indépendantes dans le modèle, leur vraisemblance jointe est un produit. θ varie ; les observations restent fixées. L(θ) n’est donc pas la probabilité que θ soit vrai.

Le logarithme transforme ce produit en somme : $\ln(\prod p_i) = \Sigma \ln(p_i)$, pour des facteurs positifs. Maximiser la vraisemblance revient alors à minimiser son logarithme négatif. Cette écriture aide à éviter des produits numériques extrêmement petits.

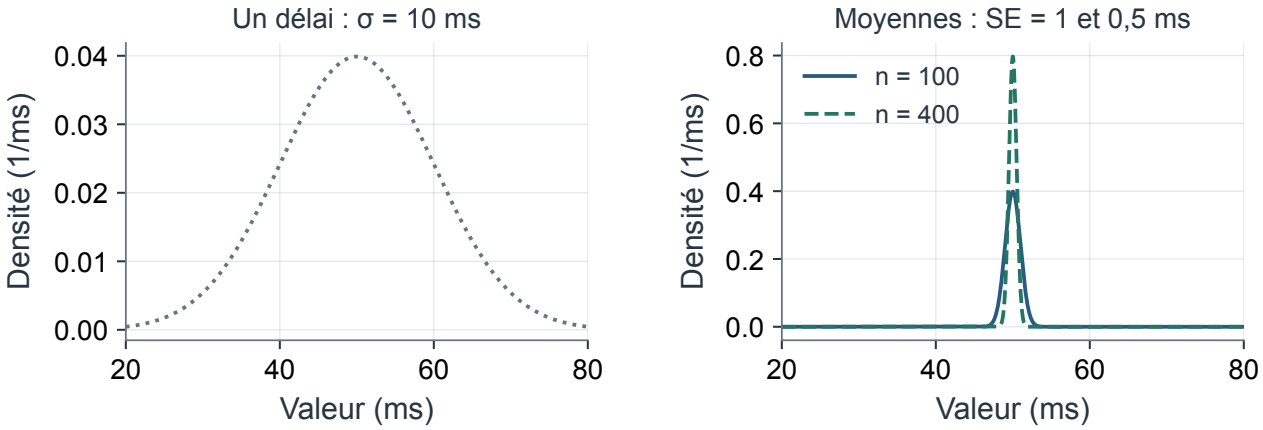
À retenir. Pour comparer deux hypothèses avec Bayes, on multiplie chacune de leurs probabilités initiales par la vraisemblance de l’observation. ∝ signifie « proportionnel à » : il reste à diviser ces poids par leur somme. Des poids 2 et 3 donnent ainsi les probabilités 2/5 = 0,4 et 3/5 = 0,6.

Dispersion et précision d’une moyenne : deux questions

Des délais peuvent rester très dispersés même si leur moyenne est estimée précisément. L’écart-type σ décrit la dispersion d’une observation ; l’**erreur standard**, notée SE, décrit celle de la moyenne calculée sur n observations indépendantes de même loi et de variance finie.

$$\mathrm{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

Si σ = 10 ms, une moyenne sur 100 observations a une erreur standard de 1 ms. Sur 400 observations, elle vaut 0,5 ms. Les observations individuelles gardent leur écart-type de 10 ms.



La moyenne se disperse moins que les observations, sous les hypothèses indiquées. Les trois courbes ont une aire égale à 1.

Que signifie un intervalle de confiance à 95 % ?

Si les observations suivent une loi normale (la courbe en cloche) et σ est connu, la procédure donne un intervalle moyenne ± 1,96σ/√n. Pour une moyenne observée de 50 ms, σ = 10 ms et n = 100, il va de 48,04 à 51,96 ms. Répétée sur de nouveaux échantillons, cette procédure couvre la vraie moyenne dans 95 % des cas. Elle ne décrit pas la plage contenant 95 % des délais individuels.

Lorsque σ est estimé, le livre utilise un coefficient de Student, qui dépend du nombre d’observations. Un intervalle étroit ne corrige ni un biais de collecte ni une dépendance ignorée entre mesures.

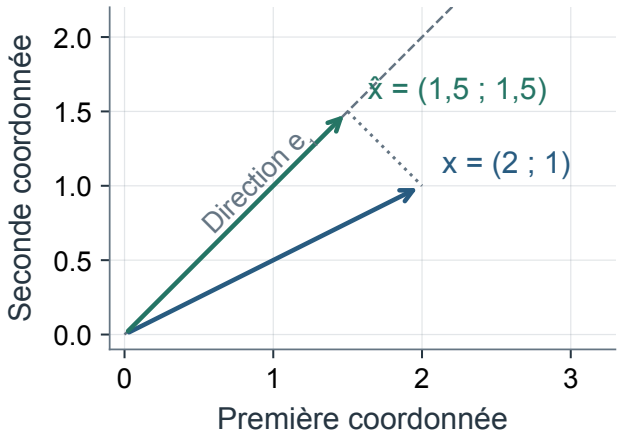
Le lien avec Monte-Carlo. On simule des observations, puis on moyenne leurs résultats. Sous les mêmes hypothèses, multiplier le nombre de simulations par quatre divise l’erreur standard par deux. Cela améliore la précision du calcul dans le modèle choisi ; cela ne rend pas ce modèle plus juste.

Projection et orthogonalité : regarder dans une direction

Pour comparer deux directions, on utilise le **produit scalaire** : $x^\top e$ additionne les produits des composantes. Deux vecteurs non nuls sont orthogonaux si leur produit scalaire vaut zéro ; dans le plan, leurs directions sont perpendiculaires.

Prenons $x = (2 ; 1)$ et deux directions de longueur 1 : $e_1 = (1 ; 1)/\sqrt{2}$ et $e_2 = (1 ; -1)/\sqrt{2}$. Leur produit scalaire vaut $(1 - 1)/2 = 0$. Elles forment une base **orthonormée** : perpendiculaires et de longueur 1.

$$c_1 = x^\top e_1 = \frac{3}{\sqrt{2}} \qquad c_2 = x^\top e_2 = \frac{1}{\sqrt{2}} \qquad x = c_1 e_1 + c_2 e_2$$



Projeter sur e_1 conserve la contribution (1,5 ; 1,5). Le résidu est perpendiculaire à e_1.

Garder les deux coefficients décrit le même vecteur dans une autre base : aucune information n'est perdue. Garder seulement c_1 reconstruit $\hat{x} = c_1 e_1 = (1{,}5 ; 1{,}5)$. Le résidu $x - \hat{x} = (0{,}5 ; -0{,}5)$ est orthogonal à e_1 ; son carré de norme vaut 0,5.

Pour une direction v qui n'a pas une longueur 1, la projection est $v(v^\top x)/(v^\top v)$. Le dénominateur corrige sa longueur.

À retenir. Une réduction de dimension élimine des composantes. L'ACP choisit quelles directions conserver selon la dispersion des données. Fourier projette aussi sur des fonctions de référence, avec un produit scalaire défini par une intégrale.

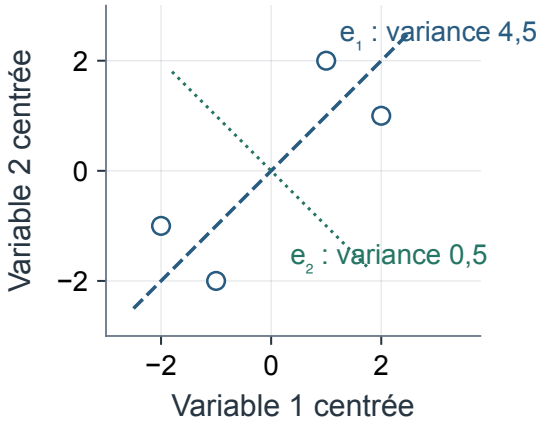
Covariance : voir comment deux variables bougent ensemble

La variance mesure la dispersion d'une variable autour de sa moyenne. La **covariance** compare les écarts de deux variables : elle est positive si elles ont tendance à monter ensemble, négative si l'une monte lorsque l'autre descend.

Pour quatre observations centrées, prenons les couples (−2 ; −1), (−1 ; −2), (1 ; 2) et (2 ; 1). Chaque colonne a une moyenne nulle. Le tableau X contient ces quatre lignes.

$$C = \frac{1}{4} X^{\top} X \qquad C_{11} = C_{22} = 2{,}5 \qquad C_{12} = C_{21} = 2$$

Les termes diagonaux valent (4 + 1 + 1 + 4)/4 = 2,5 : ce sont les variances. Les autres valent (2 + 2 + 2 + 2)/4 = 2 : c'est la covariance. On décrit ici les quatre points avec un diviseur n. Pour estimer une covariance de population à partir d'un échantillon, on utilise souvent n − 1.



Les points varient davantage le long de la première diagonale que dans la direction perpendiculaire.

Une **valeur propre** λ et son vecteur propre e vérifient Ce = λe : la transformation conserve cette direction, avec un facteur λ. Ici e_1 = (1 ; 1)/√2 a pour valeur propre 4,5 ; e_2 = (1 ; −1)/√2 a pour valeur propre 0,5.

Les variances dans ces deux directions valent donc 4,5 et 0,5. La première explique 4,5/(4,5 + 0,5) = 90 % de la variance de ces données. Ce pourcentage mesure la dispersion conservée ; il ne garantit pas 90 % de réussite d'une prédiction.

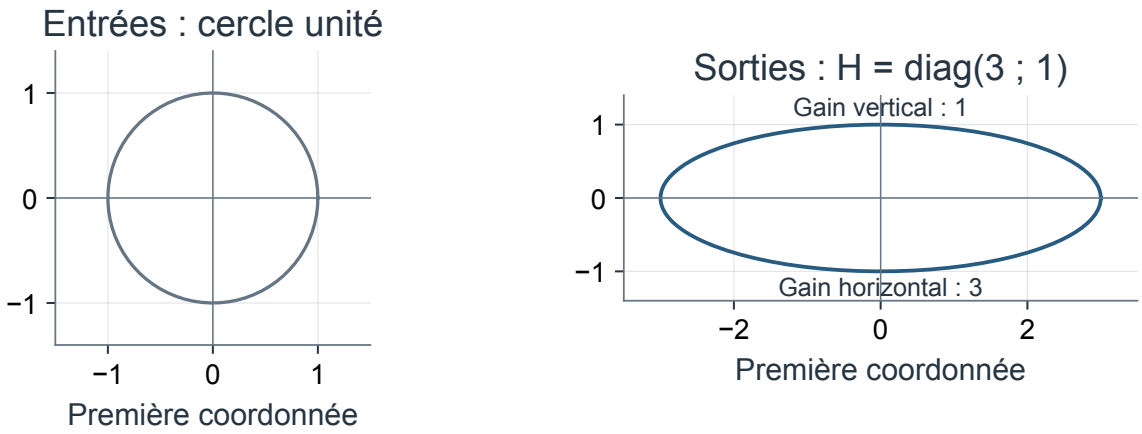
À retenir. Une covariance nulle ne garantit pas l'indépendance. Avant l'ACP, centrer et éventuellement mettre les variables à la même échelle modifie la question posée aux données.

SVD : séparer les directions et les gains

La **décomposition en valeurs singulières**, ou SVD, décrit une matrice comme trois opérations : changer de directions à l'entrée, appliquer des gains, puis exprimer le résultat dans les directions de sortie.

$$X = U\Sigma V^{\top}$$

U et V possèdent des colonnes orthonormées. Σ contient les valeurs singulières, des gains non négatifs. Dans cette formule, Σ est une matrice ; ce n'est pas le signe d'une somme. Pour une matrice rectangulaire, les tailles dépendent de la forme complète ou réduite choisie dans le texte.



La matrice diagonale H transforme le cercle unité en ellipse : gain 3 à l'horizontale, gain 1 à la verticale.

Dans le dessin, H = diag(3 ; 1) signifie que sa diagonale contient 3 et 1, les autres coefficients étant nuls. H(1 ; 0) = (3 ; 0) et H(0 ; 1) = (0 ; 1). Sa SVD a U = V = I, la matrice identité, et Σ = H. I laisse un vecteur inchangé.

Retrouver l'ACP de la page précédente

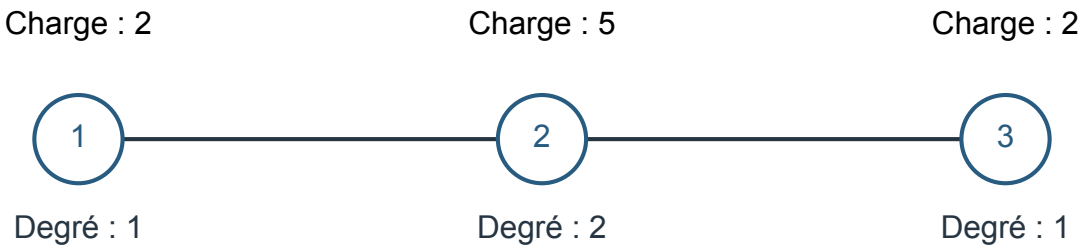
Pour le tableau centré de quatre observations, les valeurs singulières sont √18 et √2. Leurs carrés divisés par 4 donnent les valeurs propres de la covariance : 4,5 et 0,5. Les colonnes de V donnent les directions de l'ACP.

Ne conserver que le premier gain donne une approximation de rang 1. Le **rang** compte les directions indépendantes que la matrice peut produire. Pour ce tableau, la somme des carrés des erreurs de reconstruction vaut 2, le carré du gain supprimé.

À retenir. La SVD s'applique aussi aux matrices rectangulaires. Une valeur propre décrit une direction conservée par une matrice carrée ; une valeur singulière décrit un gain entre directions d'entrée et de sortie.

Graphes et matrices : mesurer un voisinage

Trois relais 1—2—3 forment une chaîne sans liaison directe entre 1 et 3. La **matrice d’adjacence** A indique les voisins ; sa diagonale vaut zéro ici, car aucun relais n’est relié à lui-même.



Trois relais en chaîne : leur charge et leur nombre de voisins sont deux informations distinctes.

$$A = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}, \quad D = \mathrm{diag}(1, 2, 1), \quad L = D - A.$$

Le **degré** compte les voisins : 1, 2 et 1. D les place sur sa diagonale. L est le **laplacien non normalisé** de ce graphe simple non orienté ; d’autres conventions existent.

Prenons les charges x = (2 ; 5 ; 2). Ax = (5 ; 4 ; 5) donne les sommes des charges voisines. Pour le relais central, diviser sa somme 4 par son degré 2 donne la moyenne 2.

$$Lx = (-3\ ;\ 6\ ;\ -3), \qquad (Lx)_i = \sum_{j \text{ voisin de } i} (x_i - x_j).$$

Chaque sortie compare la charge locale à celles des voisins. Avec la même charge partout, Lx vaut zéro. Cela éclaire les calculs de diffusion et certains réseaux neuronaux de graphes ; ce résultat n’est pas lui-même une décision de routage.

À retenir. A décrit les liaisons ; X peut décrire les observations ; L combine les liaisons et les degrés. Une matrice de transition Markov décrit des probabilités : ce n’est pas automatiquement A ou L.

À essayer — graphe. Pour cette même chaîne et x = (1 ; 4 ; 1), calculez la composante centrale de Lx.

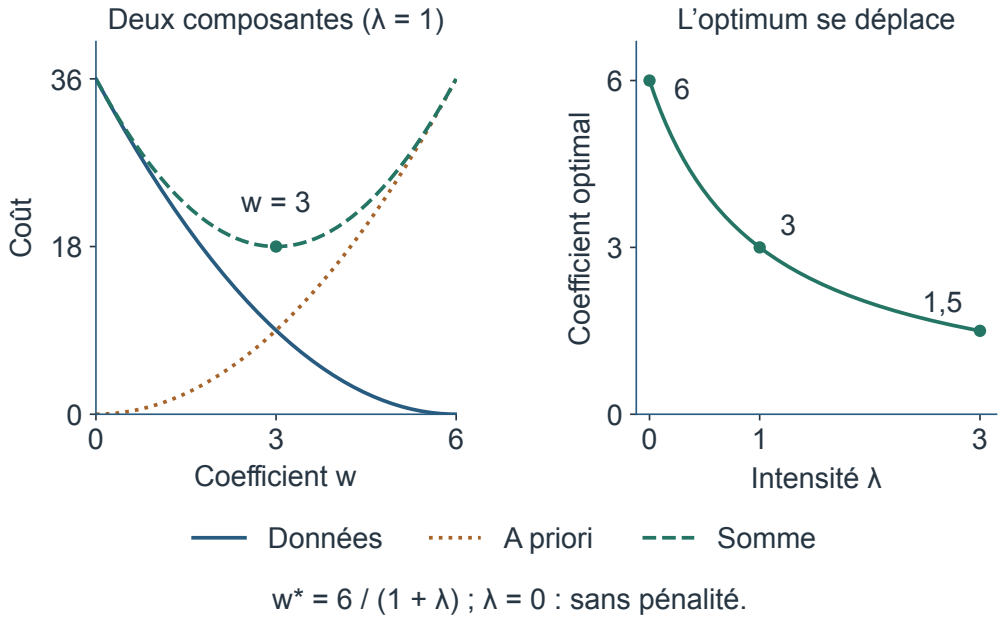
Correction — graphe. 2 × 4 − 1 − 1 = 6. Le degré central vaut 2 ; les deux voisins contribuent chacun à la différence.

13. Minimum et argmin : la valeur ou le réglage ?

Prenons le coût J(w) = (w − 6)² + w². Le premier terme rapproche w de la mesure 6 ; le second pénalise les grands coefficients.

$$\min_w J(w) = 18 \qquad \arg\min_w J(w) = 3$$

min donne la plus petite valeur du coût : 18. **argmin** donne le réglage qui atteint cette valeur : w = 3. À cet endroit, la dérivée 4w − 12 vaut zéro ; le coefficient positif du terme w² garantit ici un minimum unique.



Augmenter une pénalité déplace le compromis entre la mesure et l'a priori.

Dans J(w) = (w − 6)² + λw², λ, **lambda**, règle la force de la pénalité. L'optimum vaut 6/(1 + λ) pour λ ≥ 0 : λ = 0 donne 6, λ = 1 donne 3 et λ = 3 donne 1,5.

À retenir. θ* désigne souvent un réglage optimal ; l'étoile n'est pas une multiplication. Plusieurs réglages peuvent atteindre le même minimum, et certains problèmes n'atteignent pas leur borne inférieure.

À essayer 13. Pour J(w) = (w − 2)², donnez le minimum et un argmin.

Optimiser : vérifier le domaine et le minimum

Pour J(w) = (w − 6)², la dérivée s'annule en w = 6 : le coût y vaut zéro. Mais si le réglage doit rester entre 0 et 4, cette valeur est interdite. Le meilleur choix admissible est alors w = 4, au bord du domaine.

$$\min_{w \in [0,\,4]} (w-6)^2 = 4 \qquad \arg\min_{w \in [0,\,4]} (w-6)^2 = 4$$

Le minimum est ici un coût ; l'argmin est un réglage. Ils ont la même valeur numérique dans cet exemple, mais leurs rôles restent différents.

Une dérivée nulle ne suffit pas à prouver un minimum. Pour −w², elle s'annule en zéro, qui est un maximum. Pour w³, elle s'annule aussi en zéro, mais la courbe continue de monter.

Une fonction **convexe** reste sous la corde reliant deux points de sa courbe : pour 0 ≤ t ≤ 1,

$$J(tu + (1-t)v) \leq tJ(u) + (1-t)J(v).$$

Pour w², le milieu de 0 et 2 donne un coût de 1, inférieur à la moyenne des coûts 0 et 4, qui vaut 2. Sur un domaine convexe, tout minimum local d'une fonction convexe est aussi un minimum global ; il n'est pas forcément unique. Les pertes des réseaux neuronaux ne sont généralement pas convexes.

À retenir. Avant d'appliquer une règle de descente, lire l'objectif, le domaine autorisé et les conditions. Pour une contrainte, un optimum peut se trouver sur la frontière.

À essayer — optimisation. Minimisez (w − 5)² avec w ∈ [0,3]. Donnez le réglage optimal.

Correction — optimisation. w = 3. La valeur libre 5 est interdite ; sur [0,3], augmenter w diminue le carré. Le coût optimal vaut (3 − 5)² = 4.

14. Lire un objectif d’apprentissage en entier

Cette formule rassemble des gestes que nous avons déjà rencontrés :

$$\theta^{\star} = \arg\min_{\theta} \left[\frac{1}{n} \sum_{i=1}^{n} (y_i - f_\theta(x_i))^2 + \lambda \|\theta\|_2^2 \right]$$

La traduire dans l’ordre du calcul

1. $\mathbf{x_i}$: prendre l’observation numéro i.
2. $\mathbf{f_\theta(x_i)}$: produire une prévision avec les réglages θ.
3. $\mathbf{y_i - f_\theta(x_i)}$: comparer la réponse connue à la prévision.
4. **Le carré puis Σ/n** : calculer l’erreur moyenne sur n observations.
5. $\mathbf{\lambda\|\theta\|_2^2}$: ajouter une pénalité sur les paramètres.
6. $\mathbf{\arg\min_\theta}$: chercher les réglages qui rendent l’ensemble aussi petit que possible.

Le symbole θ placé en bas de f indique quel modèle paramétré on utilise. Le mot **données** recouvre souvent l’ensemble D = {(x_i, y_i)} : des observations et leurs réponses associées.

La phrase entière. Chercher un modèle qui prévoit correctement les réponses connues tout en limitant la taille de ses paramètres, selon la force de pénalisation choisie.

L’objectif porte ici sur l’entraînement. Sa baisse ne démontre pas la qualité des prévisions sur de nouvelles données : la validation et le test répondent à cette autre question.

À essayer 14. Si λ = 0, quel terme disparaît ? Si n double, doit-on supprimer la division par n ?

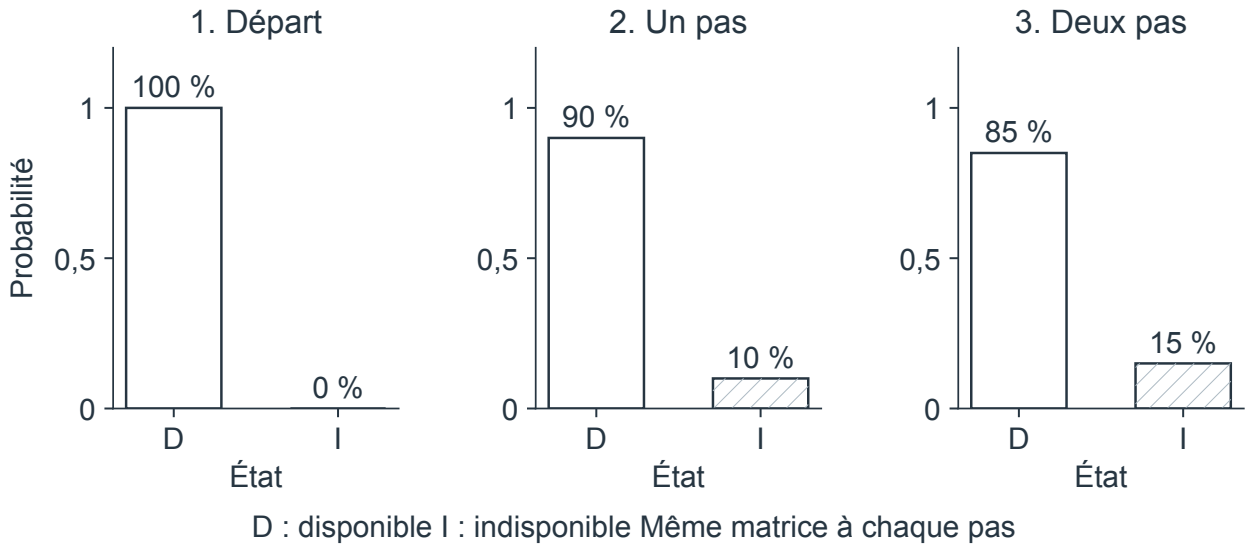
15. Markov : suivre une probabilité dans le temps

Un équipement peut être disponible D ou indisponible I. Une matrice P rassemble les probabilités de passer d'un état à l'autre en un pas de temps.

Dans cet exemple, chaque ligne indique l'état actuel, chaque colonne l'état suivant. Depuis D : 0,9 vers D et 0,1 vers I. Depuis I : 0,4 vers D et 0,6 vers I. Chaque ligne somme à 1.

$$p_{t+1} = p_t P$$

p_t est ici un vecteur **ligne** : sa première valeur donne la probabilité d'être en D, la seconde celle d'être en I. Le t en indice indique le temps ; t + 1 indique le pas suivant.



À chaque pas, les probabilités des états se recombinent par la même matrice.

Avec $p_0 = (1 ; 0)$, on obtient $p_1 = (0{,}9 ; 0{,}1)$, puis $p_2 = (0{,}85 ; 0{,}15)$. Le point-virgule sépare les composantes.

À retenir. La convention ligne ou colonne change l'ordre du produit. Avec un vecteur colonne et les mêmes probabilités, on utilise $P^\top$. L'hypothèse de Markov dit que l'état actuel suffit à décrire la transition dans le modèle retenu.

À essayer 15. À partir de p_1, calculez la probabilité d'être disponible au pas 2. Quelles deux situations y contribuent ?

Markov : équilibre ne veut pas toujours dire convergence

Le modèle précédent utilise les états disponible et indisponible. La première ligne de sa matrice de transition P vaut (0,9 ; 0,1), la seconde (0,4 ; 0,6). On utilise un vecteur ligne :

$$p_{t+1} = p_t P$$

Une distribution **stationnaire** π, ici un vecteur ligne, vérifie πP = π : une transition ne change pas ses probabilités. En écrivant π = (a ; 1 − a), la première composante impose a = 0,9a + 0,4(1 − a). On développe : a = 0,5a + 0,4, donc a = 0,8.

$$(0{,}8\ ;\ 0{,}2)P = (0{,}8\ ;\ 0{,}2)$$

Partant de (1 ; 0), la probabilité d'être disponible passe de 1 à 0,9, puis 0,85, puis 0,825. Elle se rapproche de 0,8. Si a_t désigne cette probabilité, la relation $a_{t+1} = 0{,}5a_t + 0{,}4$ divise à chaque pas l'écart à 0,8 par deux.

Un contre-exemple : alterner sans se stabiliser

Si le système passe toujours du premier état au second, puis du second au premier, sa matrice est ((0 ; 1) ; (1 ; 0)). La distribution (0,5 ; 0,5) reste stationnaire. Pourtant, en partant de (1 ; 0), les distributions alternent entre (1 ; 0) et (0 ; 1).

À retenir. Trouver un équilibre ne prouve pas que toute évolution y converge. Pour une chaîne finie, l'irréductibilité — pouvoir atteindre chaque état depuis tout autre — et l'absence de périodicité garantissent une distribution stationnaire unique et la convergence vers elle.

Bellman : lire une décision en deux temps

Une chaîne de Markov décrit les changements d'état. En **apprentissage par renforcement**, les actions peuvent modifier ces transitions. Une **politique** π, lue « pi », indique comment choisir une action dans chaque état. Ici, π ne désigne ni le nombre 3,1416 ni une distribution stationnaire.

La **valeur** $V^{\pi}(s)$ est la moyenne des récompenses futures depuis l'état s, en suivant cette politique. Le π en exposant repère la politique ; il ne demande pas d'élever V à une puissance. Le facteur γ, **gamma**, réduit le poids des récompenses lointaines : la prochaine récompense compte entièrement ; celle qui vient un pas après pèse γ fois sa valeur, deux pas après γ^2 fois sa valeur. On suppose ici des récompenses bornées et $0 \leq \gamma < 1$; leur somme actualisée reste alors finie.

L'équation de Bellman sépare la prochaine récompense et la suite du parcours :

$$V^{\pi}(s) = \mathbb{E}_{\pi}\left[r_{t+1} + \gamma V^{\pi}(S_{t+1}) \mid S_t = s\right]$$

r_{t+1} est la prochaine récompense ; S_{t+1}, l'état suivant. La barre « $\mid S_t = s$ » signifie que l'on part de s. $\mathbb{E}$ demande une moyenne ; son indice π rappelle que les actions suivent la politique. Cette moyenne tient aussi compte des transitions aléatoires. À la fin d'un épisode, la valeur future vaut zéro.

Reprendre les deux relais du livre

Après avoir choisi le relais B, les récompenses sont 0,2, puis 0,8, puis 1. La suite vaut 0,8 + 0,9 × 1 = 1,7. Pour ce parcours déterministe, dont les actions suivantes sont fixées, Bellman redonne le retour complet :

$$0{,}2 + 0{,}9 \times 1{,}7 = 1{,}73$$

Si la politique choisit B à coup sûr dans cet état, $V^{\pi}(s)$ vaut 1,73. Si elle peut choisir plusieurs actions, il faut aussi moyenner leurs résultats. Chercher la meilleure politique consiste à comparer ces retours ; prendre un maximum ne fait pas disparaître l'incertitude des transitions.

À essayer — Bellman. Une transition observée donne une récompense 1. Avec γ = 0,9 et une estimation de valeur −2 pour l'état suivant, quelle cible calcule-t-on ? Si la valeur estimée de l'état actuel est 0,5, quelle est la différence « cible − estimation » ?

Pour approfondir : la valeur et les équations de Bellman dans Dive into Deep Learning.

16. Rétropropagation : lire les dérivées par étapes

Un petit réseau suffit pour voir le mécanisme. Son unité cachée calcule h = max(0, $w^\top x$ + b). Cette fonction, appelée ReLU, conserve une valeur positive et remplace une valeur négative par zéro. La sortie est linéaire : ŷ = vh + c.

$$L = \tfrac{1}{2}(\hat{y} - y)^2 \qquad e = \hat{y} - y$$

Le chapeau de ŷ désigne une prévision. Pour x = (2 ; 1), w = (1 ; −1), b = 0, v = 3 et c = 0, on trouve h = 1, ŷ = 3. Si la cible y vaut 5, e = −2 et L = 2.

Sortie : d’où vient l’erreur ?

La dérivée de L par rapport à ŷ vaut e. Comme ŷ = vh + c, on obtient ∂L/∂v = eh = −2 et ∂L/∂c = e = −2.

Couche cachée : comment l’erreur remonte-t-elle ?

La ReLU reçoit ici une entrée positive : sa dérivée vaut 1. Le signal caché vaut ev = −6. Chaque poids reçoit ce signal multiplié par son entrée :

$$\frac{\partial L}{\partial w_j} = evx_j \qquad \frac{\partial L}{\partial b} = ev$$

On trouve −12 pour w_1, −6 pour w_2 et −6 pour b. C’est la **règle de la chaîne** : multiplier les sensibilités successives. Avec une entrée cachée négative, la dérivée ReLU vaut zéro ; au point zéro, la fonction n’est pas dérivable.

À retenir. Ces formules correspondent à cette sortie linéaire et à cette perte. Une sortie softmax avec entropie croisée se traite avec ses propres dérivées.

À essayer 16. Que vaut la dérivée de la perte par rapport à v si h vaut 0 ?

17. Hypothèses, quantificateurs et démonstrations

Une thèse précise souvent de quels objets elle parle : $x \in \mathbb{R}$ signifie « x est un nombre réel » ; $x \in \mathbb{R}^d$ signifie « x est un vecteur de d nombres réels ». Le symbole $\in$ se lit « appartient à ».

Deux mots qui changent une affirmation

• **∀** se lit « pour tout ». L'affirmation concerne tous les objets du domaine indiqué.

• **∃** se lit « il existe ». Il suffit de trouver un objet qui convient.

« Pour chaque tâche, il existe un modèle qui convient » autorise un modèle différent par tâche. « Il existe un modèle qui convient à toutes les tâches » demande un seul modèle commun. L'ordre des mots, et des quantificateurs, change le sens.

Une courte démonstration que l'on peut suivre

Pour f(x) = wx + b, avec w fixé, deux entrées x et z vérifient :

$$|f(x) - f(z)| = |w(x - z)| = |w|\,|x - z|$$

La première égalité remplace la fonction par sa définition : les deux b s'annulent. La seconde utilise la règle du produit des valeurs absolues.

Cette égalité montre que l'écart de sortie est limité par |w| fois l'écart d'entrée. On dit que f est **Lipschitz**, avec cette constante. C'est une propriété démontrée pour tous les réels x et z, pas un résultat observé sur quelques exemples.

À retenir. ⇒ signifie « implique » ; ⇔ signifie « équivaut à », donc implication dans les deux sens.

À essayer 17. Pour w = 3, quel écart maximal cette relation donne-t-elle si les entrées diffèrent de 0,2 ?

18. Einstein : lire une somme implicite

La convention de sommation d'Einstein peut faire disparaître Σ de l'écriture sans enlever l'addition du calcul. Nous l'utilisons ici pour des tableaux de nombres en coordonnées euclidiennes.

Dans un produit à droite de l'égalité, un indice répété deux fois est additionné sur ses valeurs possibles. Un indice présent une seule fois reste dans le résultat.

$$a_i b_i = \sum_{i=1}^{2} a_i b_i = 2 \times 4 + 3 \times 1 = 11$$

Avec a = (2 ; 3) et b = (4 ; 1), i parcourt les deux positions. Le résultat est un scalaire : aucun indice ne reste. C'est le produit scalaire déjà rencontré.

$$C_{ij} = A_{ik} B_{kj} = \sum_{k=1}^{3} A_{ik} B_{kj}$$

k est l'**indice sommé**, aussi appelé indice muet. i et j sont les **indices libres** : ils choisissent une case de C.

L'indice k est additionné ; i et j restent.

A[i,k] : 2 × 3	×	B[k,j] : 3 × 4	=	C[i,j] : 2 × 4
i : ligne ; k : colonne		k : ligne ; j : colonne		i : ligne ; j : colonne

Pour une case de C : trois produits sont additionnés sur k.

Les deux dimensions repérées par k se contractent ; i et j donnent les axes du résultat.

En IA, un **tenseur** est un tableau à plusieurs axes. **Contracter**, c'est additionner sur des axes communs.

À retenir. Cette convention doit être annoncée. En géométrie, la position haute ou basse des indices porte aussi un sens ; les calculs de cette page utilisent une même base euclidienne.

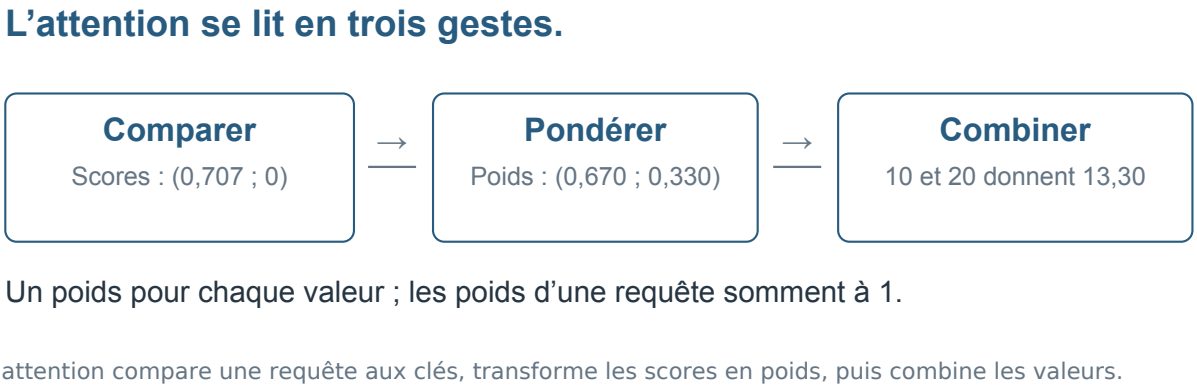
À essayer 18. Dans $Z_{ij} = U_{ia} V_{aj}$, quel indice est additionné ? Quels indices restent ? Si U est de dimension 2 × 3 et V de dimension 3 × 4, quelle est la dimension de Z ?

En code : einsum de NumPy.

19. Une vraie équation d’article : l’attention

L’article de Vaswani et ses coauteurs, *Attention Is All You Need* (2017), décrit l’attention par produit scalaire mis à l’échelle :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$



L’attention compare une requête aux clés, transforme les scores en poids, puis combine les valeurs.

Q représente les requêtes, K les clés et V les valeurs. Leur rôle se retient par trois verbes : **chercher, comparer, combiner**. d_k est le nombre de composantes utilisées pour comparer une requête à une clé.

Pour une requête Q = (1 ; 0), deux clés (1 ; 0) et (0 ; 1), le produit $QK^\top$ donne les scores (1 ; 0). La division par √2 donne environ (0,707 ; 0).

Les exponentielles des deux scores valent environ 2,028 et 1. On divise chacune par leur somme, 3,028 : **2,028/3,028 ≈ 0,670** et **1/3,028 ≈ 0,330**. Ce sont les poids de la première et de la seconde clé.

Avec les deux valeurs 10 et 20, la sortie vaut environ 0,670 × 10 + 0,330 × 20 = **13,30**. C’est une combinaison pondérée.

À retenir. La softmax s’applique ici à chaque ligne de scores. Le mot « attention » désigne ce calcul ; il ne prouve pas une compréhension humaine.

À essayer 19. Si les deux scores sont égaux et les valeurs 10 et 20, quelle sortie obtient-on ?

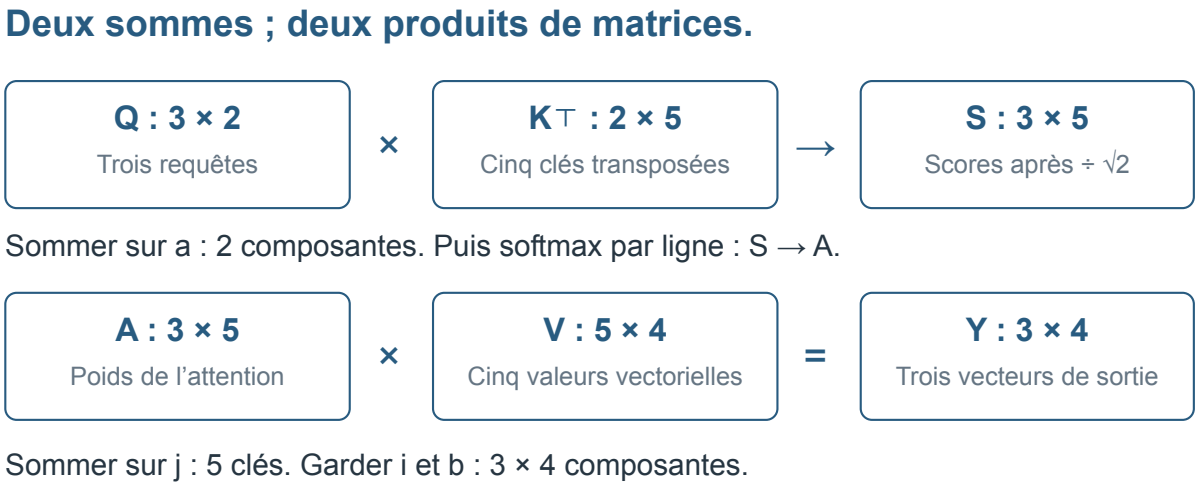
Source de l’équation : Vaswani et al., 2017, section 3.2.1.

L’attention, indice par indice

S désigne les scores, A = softmax(S) les poids, Y la sortie. Pour une tête d’attention :

$$S_{ij} = \frac{Q_{ia}K_{ja}}{\sqrt{d_k}} \qquad Y_{ib} = A_{ij}V_{jb}$$

Sommer sur a compare les composantes d’une requête et d’une clé. **Sommer sur j** combine les valeurs. i choisit une requête, j une clé et sa valeur, b une composante de sortie.



Deux produits : des scores entre requêtes et clés, puis des vecteurs de sortie.

$K^\top$ transpose les clés. La softmax agit par ligne, avec une somme explicite au dénominateur. Le schéma montre une attention entre deux séquences de longueurs différentes.

Où est le Transformer ?

En **auto-attention**, X contient les vecteurs d’une même séquence. Trois matrices apprises donnent $Q = XW_Q$, $K = XW_K$ et $V = XW_V$: autant de requêtes que de clés.

Plusieurs **têtes** répètent ce calcul avec leurs propres paramètres ; leurs sorties sont réunies et transformées. Le Transformer ajoute notamment des réseaux appliqués à chaque élément et des informations de position.

À retenir. La convolution partage des poids dans une fenêtre locale. L’attention adapte ses poids au contenu ; un masque peut limiter les positions accessibles.

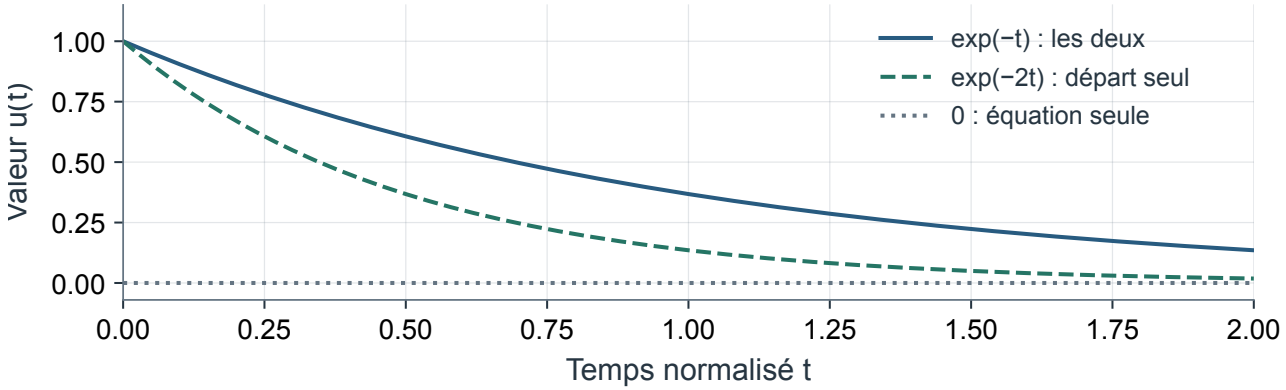
Blocs complets : Vaswani et al., 2017, sections 3.1–3.5.

PINN : apprendre une courbe qui respecte une équation

Une **équation différentielle** relie une fonction à ses dérivées. Prenons un modèle simple de décroissance, avec un temps normalisé t sans unité : u′(t) + u(t) = 0 et u(0) = 1. On cherche toute une courbe, et non un nombre isolé.

$$u(t) = e^{-t} \qquad u'(t) = -e^{-t} \qquad u'(t) + u(t) = 0$$

La courbe vérifie aussi u(0) = e^0 = 1. L'exponentielle est égale à sa propre dérivée. Dans e^{-t}, la règle de composition apporte le facteur −1 : c'est la dérivée de −t.



Trois courbes : seule exp(−t) satisfait ensemble l'équation et la condition initiale.

Un **PINN** (*Physics-Informed Neural Network*, « réseau neuronal informé par la physique ») propose une courbe u_θ à l'aide d'un réseau neuronal. Le **résidu** $r_\theta(t) = u'_\theta(t) + u_\theta(t)$ mesure l'écart à l'équation. Aux points de contrôle $t_1, \ldots, t_m$, une composante du coût moyenne les résidus au carré :

$$J_{\text{phys}} = \frac{1}{m}\sum_{k=1}^{m} r_\theta(t_k)^2 \qquad J_{\text{init}} = (u_\theta(0) - 1)^2$$

La courbe u = 0 a un résidu nul, mais Jinit = 1 : elle viole la condition de départ. La courbe u = e^{-2t} respecte le départ, mais son résidu vaut $-e^{-2t}$; au temps 0, son carré vaut 1.

À retenir. Un entraînement peut minimiser une somme pondérée de ces composantes, éventuellement avec des données. La page suivante compare cette stratégie à un minimax. Un faible résidu sur quelques points ne prouve pas que toute la courbe est correcte : il faut aussi vérifier ailleurs.

20. Minimax : deux composantes, deux façons de décider

Un PINN apprend en utilisant des données et une contrainte physique. Sa perte peut combiner une composante J_1 liée aux observations et une composante J_2 liée au résidu d'une équation physique : l'écart entre ce que prédit le réseau et ce que cette équation impose.

Une somme pondérée choisit des poids, puis minimise le total :

$$\min_{\theta} [aJ_1(\theta) + (1-a)J_2(\theta)] \qquad 0 \le a \le 1$$

Un autre objectif consiste à minimiser la pire composante. On peut le formuler comme un minimax :

$$\min_{\theta} \max_{0 \le q \le 1} [qJ_1(\theta) + (1-q)J_2(\theta)] = \min_{\theta} \max(J_1(\theta), J_2(\theta))$$

Pour un θ fixé, le choix de q peut porter tout le poids sur la plus grande des deux composantes. Il faut ensuite chercher θ.

Comparons deux réglages : A donne (0,1 ; 0,9), B donne (0,6 ; 0,6). Avec des poids égaux, les coûts valent 0,5 et 0,6 : A est préféré. Pour la pire composante, les coûts valent 0,9 et 0,6 : B est préféré.

À retenir. Le minimax change l'objectif. Un PINN ordinaire n'est pas automatiquement entraîné ainsi. Les deux composantes doivent être comparables : unités et mise à l'échelle comptent.

À essayer 20. Quel réglage le minimax préfère-t-il entre C = (0,2 ; 0,8) et D = (0,5 ; 0,5) ?

21. Ouvrir une thèse et trouver son chemin

Commencez par le résumé et la question étudiée. Cherchez ensuite un schéma d'ensemble et un exemple. Les notations prennent plus facilement sens quand on sait déjà ce que les auteurs essaient de résoudre.

Une première lecture en quatre gestes

1. **Nommer les objets.** Donnée, paramètre, matrice, fonction, probabilité ou ensemble ? Notez leur dimension et leur unité.

2. **Déplier le calcul.** Remplacez une somme par deux termes, une matrice par un petit tableau ou un objectif par deux réglages.

3. **Lire les conditions.** La formule demande-t-elle une indépendance, une dérivabilité, une borne, un nombre fini d'éléments ou des données du même domaine ?

4. **Relier à la conclusion.** Est-ce une définition, une démonstration, une hypothèse de modèle ou un résultat expérimental ?

Des symboles qui changent de métier

θ désigne souvent des paramètres ; λ peut être une pénalité ou une valeur propre. Dans $Av = \lambda v$, le vecteur v garde sa direction sous l'action de A, avec un facteur λ. Une lettre familière ne dispense donc pas de lire sa définition.

Une barre peut indiquer une moyenne ; un chapeau, une estimation ; une étoile, un optimum. Les crochets servent aussi à grouper ou à désigner un élément de tableau. Le contexte tranche.

Une pratique utile. Constituez un petit lexique sur une feuille : symbole, sens, dimension, endroit où il est défini. Revenez aux équations importantes après avoir lu un exemple.

Une thèse à explorer. Celle de Seif Eddine Hammami, consacrée aux données et aux ressources des réseaux cellulaires, permet d'essayer cette démarche. Commencez par sa question et ses données ; choisissez ensuite une seule figure ou équation à expliquer avec vos propres mots.

À essayer 21. Une courbe montre une baisse de perte sur l'entraînement. Quelles informations chercher avant d'en conclure que le modèle prédit mieux sur de nouveaux cas ?

Un lexique pour les symboles qui restent à rencontrer

Lisez d’abord le rôle et la dimension de chaque objet. Une lettre grecque ne fixe pas son sens : le texte la définit.

• **∑ / ∏** : additionner / multiplier une famille de termes. L’indice et ses bornes disent lesquels.

• **∝** : proportionnel à. Il manque un facteur de normalisation ; des probabilités doivent finalement sommer à 1 ou avoir une densité d’aire 1.

• **$X \sim N(\mu, \sigma^2)$** : « X suit une loi normale de moyenne μ et de variance σ^2 ». Ici ∼ désigne une distribution. Dans un texte d’analyse, f ∼ g peut au contraire signifier que leur rapport tend vers 1.

• **≈ / =** : approximation / égalité. Une valeur arrondie telle que $\sqrt{2} \approx 1{,}414$ ne remplace pas une égalité exacte.

• **A^{-1}** : matrice inverse, lorsqu’elle existe ; $A^{-1}A = AA^{-1} = I$. Pour $A = \mathrm{diag}(2 ; 4)$, $A^{-1} = \mathrm{diag}(0{,}5 ; 0{,}25)$. Le signe −1 n’inverse pas séparément chaque case d’une matrice quelconque.

• **A ⊙ B** : produit terme à terme de tableaux de même taille. Pour $A = \mathrm{diag}(2 ; 4)$ et B rempli de 1, $A \odot B = A$; le produit matriciel AB vaut $((2 ; 2) ; (4 ; 4))$.

• **n!**, lu « factorielle n » : produit $1 \times 2 \times \dots \times n$; $3! = 6$ et $0! = 1$. Il apparaît au dénominateur des développements de Taylor.

• **μ, σ, λ, θ, η, φ, ν, γ** : mu, sigma, lambda, thêta, êta, phi, nu, gamma. Ici, ils ont servi à une moyenne, une dispersion, une pénalité ou valeur propre, des paramètres, un pas, une phase, une fréquence et un facteur d’actualisation.

• **π**, pi : le nombre 3,1416 dans un angle, une distribution stationnaire dans la chaîne de Markov, une politique dans l’apprentissage par renforcement. Sa définition locale décide du sens.

• $\mathbb{R}^d$ / $\mathbb{C}^d$: vecteurs à d composantes réelles / complexes. **$x \in \mathbb{R}^d$** se lit « x appartient à cet ensemble » ; **∈** signifie « appartient à ».

À retenir. Dans le livre, σ peut aussi désigner une fonction d’activation et Σ une matrice de gains. Recopier la définition locale évite de transporter le sens d’un chapitre dans un autre.

Du guide aux calculs de la collection

Choisissez la question qui vous intéresse. Refaites son exemple dans ce guide, puis ouvrez le développement correspondant. Chaque lien rejoint la section du volume indiqué ; la destination suit sa pagination lors de l'export.

• **Une capacité radio.** Logarithmes, unités et décibels → Shannon, puis décibels, dans le volume d'ingénierie.

• **Une file d'attente.** Isoler une variable, lire une fraction → arrivées, service et stabilité, dans le volume d'ingénierie. Dans $W = 1/(\mu - \lambda)$, μ doit dépasser λ.

• **Un signal à décomposer.** Sinus, phase et Fourier → Taylor et Fourier, dans le volume IA. Taylor approxime localement ; Fourier décompose selon des fréquences.

• **Une décision et ses conséquences.** Markov, espérance et actualisation → Bellman et les deux relais, dans le volume IA.

• **Réduire un tableau de mesures.** Projection, covariance et SVD → ACP, puis projection expliquée, dans le volume IA.

• **Lire une probabilité continue.** Densité, répartition et indépendance → densités et Bayes, dans le volume IA.

• **Entraîner un réseau.** Composition, gradient et rétropropagation → calcul des couches, dans le volume IA.

• **Respecter une dynamique.** Équation différentielle, résidu et minimax → PINN, dans le volume IA.

• **Estimer par simulation.** Dispersion et erreur de moyenne → Monte-Carlo, puis intervalle de confiance, dans le volume d'ingénierie.

• **Retrouver un sujet de concours.** La préparation facultative en fin de guide → sujets ENSI et corrigés, dans le complément historique.

Pour ouvrir les renvois. Téléchargez les PDF actuels de la collection et placez-les dans le même dossier que ce guide. Un lecteur PDF peut demander une confirmation avant d'ouvrir un autre fichier. Le dossier partagé permet aussi de choisir le volume à lire en ligne.

22. Réutiliser ce que l’on a appris

Ces questions relient plusieurs étapes. Prenez une feuille ; écrivez d’abord une phrase, puis le calcul.

A. Choisir une mesure d’erreur

Trois réponses connues valent (2 ; 4 ; 6). Le modèle prévoit (1 ; 4 ; 8). Calculez l’erreur quadratique moyenne. Dites ce que signifie l’indice i.

B. Lire un produit

X a 40 lignes et 3 colonnes. w contient 3 poids. Le vecteur b contient un décalage par observation. Quelles sont les dimensions de Xw + b ?

C. Corriger un réglage

$J(w) = (w - 5)^2$. Au point $w = 1$, calculez la dérivée. Appliquez un pas de 0,1 dans le sens de la descente. Comparez les coûts avant et après.

D. Interpréter une alarme

Parmi 50 alarmes, 10 correspondent à un incident. Quel nombre représente P(incident | alarme) ? Peut-on en déduire P(alarme | incident) sans autre donnée ?

E. Vérifier une borne

Une fonction vérifie $|f(x) - f(z)| \leq 2|x - z|$ pour tous les réels x et z. Si les entrées diffèrent de 0,3, quelle borne peut-on donner sur l’écart de sortie ? Cette borne impose-t-elle un écart exactement égal à cette valeur ?

F. Relire l’attention

Dans la formule de l’attention, Q a la dimension 3×2, K la dimension 5×2 et V la dimension 5×4. Quelles sont les dimensions des scores puis de la sortie ?

Les corrections expliquent le raisonnement. Si une étape bloque, revenez à sa page plutôt que de mémoriser seulement le résultat.

Quatre calculs à retrouver dans le livre

Ces exercices complètent les six situations précédentes. Les corrigés sont réunis après leurs réponses. Pour chaque résultat, ajoutez une phrase qui explique ce qu'il signifie et vérifiez son unité.

G. Shannon : convertir avant d'appliquer

Une liaison utilise B = 2 MHz et un rapport signal/bruit de 20 dB. Convertissez ce rapport en valeur linéaire, puis calculez $C = B \log_2(1 + S/N)$. Une calculatrice accepte souvent ln : utilisez $\log_2(x) = \ln(x)/\ln(2)$. Est-ce une mesure du débit réel ou une capacité du modèle ?

H. Projection : voir ce qui est perdu

Reprenez x = (2 ; 1) et e = (1 ; 1)/√2. Calculez $c = x^\top e$, puis $\hat{x} = ce$. Calculez la différence $x - \hat{x}$ et le carré de sa norme. Vérifiez que ce résidu est orthogonal à e. Que changerait le fait de conserver aussi la seconde direction ?

I. Densité : une hauteur peut dépasser un

Un délai uniforme entre 0 et 0,5 seconde a une densité 2 par seconde. Quelle est la probabilité qu'il soit compris entre 0,1 et 0,3 seconde ? Que vaut F(0,3) ? Quelle est la probabilité qu'il vaille exactement 0,3 seconde dans ce modèle continu ?

J. PINN : deux composantes à satisfaire

On cherche $u' + u = 0$ avec $u(0) = 1$. Comparez les candidats $u_1(t) = 0$ et $u_2(t) = e^{-2t}$. Calculez pour chacun le résidu au temps 0 et le carré de l'écart initial. Pourquoi examiner une seule composante ferait-il accepter une mauvaise solution ? Proposez enfin une courbe satisfaisant les deux.

Réponses aux questions 1 à 9

1. $x_3 = 4$; $(x_3)^2 = 16$. La fonction donne $f(4) = 2 \times 4 + 1 = 9$. L’indice choisit la valeur avant le calcul.

2. Les carrés valent 4, 1 et 9 : leur moyenne est 14/3, soit environ 4,67. La somme des écarts signés vaut 2 ; des erreurs opposées peuvent s’annuler. Les carrés empêchent cette annulation.

3. X : 100×5. w : 5×1. Xw : 100×1. Une prévision est produite pour chacune des 100 observations.

4. $\|x\|_1 = 3 + 4 = 7$; $\|x\|_2 = \sqrt{25} = 5$; $\|x\|_2^2 = 25$. Le signe moins ne change pas ces longueurs.

5. En $x = 3$: $2 \times 3 = 6$. En $x = -1$: $2 \times (-1) = -2$. La courbe descend localement quand on avance depuis une entrée négative.

6. La modification vaut $-0{,}1 \times 6 = -0{,}6$. Le paramètre diminue de 0,6.

7. $4 \times 3 = 12$ Mbit. Un rectangle de largeur 3 secondes et de hauteur 4 Mbit/s a cette aire. Les unités de temps se simplifient dans le produit.

8. $y[0] = 0{,}5 \times 2 + 0{,}5 \times 0 = 1$; $y[4] = 0{,}5 \times 0 + 0{,}5 \times 8 = 4$. Chaque calcul utilise une mesure et un zéro ajouté. Le résultat au bord dépend donc du prolongement choisi.

9. En haut à gauche : $1 - 1 = 0$; en haut à droite : $2 - 3 = -1$; en bas à gauche : $0 - 0 = 0$; en bas à droite : $1 - 1 = 0$. La sortie est donc $((0 ; -1) ; (0 ; 0))$. Avec un pas de 2 sans padding, seule la première fenêtre tient entièrement dans l’image : la sortie est de dimension 1×1.

Pour retenir. Relisez chaque réponse en cachant les nombres. La phrase qui explique le geste est celle que vous pourrez réutiliser.

Réponses aux questions 10 à 21

10. $e^0 = 1$ pour les deux scores. Chaque poids vaut $1/(1 + 1) = 0,5$; leur somme vaut 1.

11. Les alarmes sont désormais 30 ; six correspondent toujours à un incident. $P(B \mid A) = 6/30 = 0,20$. Le nombre d'incidents reste huit : ce sont les alarmes sans incident qui ont augmenté.

12. La moyenne vaut 3 et chaque écart vaut zéro : la variance est nulle.

13. $J(2) = 0$: le minimum vaut 0 et l'argmin est 2. Tous les autres réglages donnent un carré positif.

14. La pénalité disparaît. La division par n reste : elle garde une moyenne par observation, même quand le nombre de cas augmente.

15. On peut rester disponible : $0,9 \times 0,9 = 0,81$. On peut aussi revenir de I : $0,1 \times 0,4 = 0,04$. La somme vaut 0,85.

16. $\partial L/\partial v = eh = 0$. Dans ce calcul, une unité cachée inactive n'envoie aucune contribution à ce poids.

17. $|w| \times 0,2 = 3 \times 0,2 = 0,6$. Pour cette fonction affine, l'égalité donne même l'écart exact.

18. a apparaît deux fois dans le produit : on additionne sur ses trois valeurs. i et j restent ; la dimension de Z est 2×4. La contraction enlève l'axe commun du calcul, sans enlever les lignes de U ni les colonnes de V.

19. Des scores égaux donnent des poids 0,5 et 0,5. Leur combinaison vaut $0,5 \times 10 + 0,5 \times 20 = 15$.

20. La pire composante de C vaut 0,8 ; celle de D vaut 0,5. Le minimax préfère D.

21. Chercher les résultats sur des données indépendantes, leur représentativité, la métrique utilisée et la séparation entre entraînement, validation et test. La baisse du coût d'entraînement ne suffit pas à conclure sur les nouveaux cas.

Un repère de progression. Vous pouvez désormais déplier une équation, calculer un petit exemple et formuler les conditions à vérifier. Un texte plus avancé demandera d'autres notions ; vous disposez d'une méthode pour les aborder.

Corrections des six situations

A. Les écarts sont (1 ; 0 ; −2). Leurs carrés valent (1 ; 0 ; 4). La moyenne vaut 5/3, soit environ 1,67. i repère une observation et relie sa réponse à sa prévision.

B. Xw donne 40 × 1. Pour additionner b, il faut un décalage pour chacune des 40 sorties : b est aussi de dimension 40 × 1. La sortie garde cette dimension.

C. $J'(w) = 2(w - 5)$, donc $J'(1) = -8$. Le nouveau réglage vaut $1 - 0{,}1 \times (-8) = 1{,}8$. Le coût passe de 16 à $(1{,}8 - 5)^2 = 10{,}24$.

D. P(incident | alarme) = 10/50 = 0,20. Pour l’autre sens, il manque le nombre total d’incidents, y compris ceux sans alarme.

E. L’écart de sortie est inférieur ou égal à 2 × 0,3 = 0,6. Il peut être plus petit : ≤ donne une borne, pas une égalité.

F. $K^\top$ a la dimension 2 × 5. $QK^\top$ a donc la dimension 3 × 5 : un score pour chacune des cinq clés et chacune des trois requêtes. La softmax conserve cette dimension. Le produit par V, de dimension 5 × 4, donne une sortie 3 × 4.

Revenir à son métier

Choisissez une formule rencontrée au travail. Traduisez-la en une phrase, identifiez les unités et remplacez ses données par deux ou trois petits nombres. Expliquez ensuite ce calcul à quelqu’un en écoutant l’endroit où il hésite. Cette hésitation révèle souvent une définition à reprendre.

Corrigés des quatre calculs du livre

G. La capacité de Shannon

20 dB correspond à $10^2 = 100$ en rapport de puissances. $B = 2 \times 10^6$ Hz, donc $C = 2 \times 10^6 \times \ln(101)/\ln(2) \approx 13{,}32 \times 10^6$ bit/s, soit 13,32 Mbit/s. Ce résultat est une capacité dans le modèle de canal ; le débit effectif dépend aussi du codage, des protocoles et des conditions réelles. Insérer directement 20 au lieu de 100 dans le logarithme donnerait un résultat incorrect.

H. La projection

$c = (2 + 1)/\sqrt{2} = 3/\sqrt{2}$. En multipliant par e, on obtient $\hat{x} = (3/2 ; 3/2)$. Le résidu vaut $(0{,}5 ; -0{,}5)$. Son produit scalaire avec e vaut $(0{,}5 - 0{,}5)/\sqrt{2} = 0$: il est orthogonal. Son carré de norme vaut $0{,}5^2 + (-0{,}5)^2 = 0{,}5$. Garder aussi la seconde direction permet de reconstruire exactement x : changer de base ne perd pas d’information.

I. L’aire de la densité

La longueur de l’intervalle vaut $0{,}3 - 0{,}1 = 0{,}2$ seconde. Sa probabilité vaut 2 par seconde × 0,2 seconde = 0,4. Les unités s’annulent. $F(0{,}3)$ vaut $2 \times 0{,}3 = 0{,}6$. La probabilité d’une valeur exacte vaut zéro dans cette loi continue ; une mesure arrondie correspond à un intervalle et peut avoir une probabilité positive.

J. Le résidu et le départ

Pour $u_1 = 0$, la dérivée vaut 0 : le résidu vaut 0, mais $(u_1(0) - 1)^2 = 1$. Pour $u_2 = e^{-2t}$, la dérivée vaut $-2e^{-2t}$, donc le résidu vaut $-e^{-2t}$. Au temps 0, il vaut -1 et son carré vaut 1 ; le coût initial vaut 0. Les deux candidats satisfont une composante et violent l’autre. La courbe $u = e^{-t}$ satisfait ensemble l’équation et le départ.

Pour reprendre. Une erreur de calcul ramène aux gestes de base ; une difficulté à expliquer le résultat ramène au dessin et à la question de départ. Refaites ensuite l’exercice avec d’autres nombres.

Réponses aux repères de l’IA

La dérivée calculée automatiquement

En w = 0, u = 0 et v = −1. Le carré apporte 2v = −2. En remontant, on obtient dJ/dw = (−2) × 1 × 3 = −6. Le signe moins signifie que le coût diminue localement lorsqu’on augmente w depuis zéro.

La température

Les deux scores restent nuls après division par n’importe quelle température positive. Les exponentielles valent 1 et 1 : les probabilités sont 0,5 et 0,5 pour T = 0,5 comme pour T = 2. Une température ne départage pas des scores égaux.

La normalisation

(25 − 20)/10 = 0,5. En secondes : (0,025 − 0,020)/0,010 = 0,5. Ce délai se situe un demi-écart-type au-dessus de la moyenne. Changer d’unité ne change pas cette position relative.

La confiance

La fréquence observée vaut 70/100 = 70 %. L’écart à l’annonce de 90 % vaut 20 points de pourcentage. Le modèle est trop confiant sur ce groupe ; on doit examiner aussi d’autres plages de confiance et des données représentatives de l’usage.

Bellman

La cible vaut 1 + 0,9 × (−2) = −0,8. La différence avec la valeur estimée vaut −0,8 − 0,5 = −1,3 : c’est l’erreur de différence temporelle, ou **erreur TD**. Elle est négative malgré la récompense immédiate positive. Cette cible utilise une estimation de la suite ; elle ne prouve pas que la vraie valeur est −0,8.

Pour retenir. Refaites ces questions avec d’autres nombres. Le graphe, le tirage, l’échelle, la fréquence observée et le retour futur donnent chacun une façon de lire un calcul d’IA.

Les sujets ENSI : une préparation facultative

Les sujets de concours présents dans le livre mettent en regard les mathématiques apprises vers vingt ans et celles utilisées bien plus tard. Vous pouvez lire les dossiers d'IA sans résoudre ces sujets. Pour entrer dans leurs corrigés, quelques mots supplémentaires sont utiles.

Un polynôme est une fonction faite de puissances

$P(X) = 2X^2 + 3X + 1$ est de **degré 2** : sa plus grande puissance ayant un coefficient non nul est 2. L'ensemble $\mathbb{R}_n[X]$ rassemble les polynômes à coefficients réels de degré au plus n, avec le polynôme nul. La liste $(1, X, \ldots, X^n)$ en forme une base : chaque polynôme y est une combinaison de n + 1 fonctions.

Dans le sujet de mathématiques II, un opérateur transforme un polynôme en un autre :

$$L(P) = (X^2 - 1)P'' + 3XP'$$

P' et P'' sont les première et deuxième dérivées. Pour $P = X^2$, elles valent $2X$ et 2. On obtient $L(X^2) = 2(X^2 - 1) + 6X^2 = 8X^2 - 2$. Le résultat reste de degré au plus 2. L est **linéaire** : $L(aP + bQ) = aL(P) + bL(Q)$, pour des coefficients réels a et b. Transformer une combinaison revient à combiner les transformations. Dire que L est un **endomorphisme** signifie qu'il est linéaire et reste dans l'espace considéré.

Reconnaître ce qu'il reste à apprendre

Pour les intégrales du sujet de mathématiques I, les primitives, les changements de variable, les intégrales impropres et les intégrales doubles demandent un apprentissage supplémentaire. Une intégrale double accumule sur une surface ; changer l'ordre d'intégration demande des conditions, telles que celles du théorème de Fubini. Le corrigé du livre détaille ces étapes.

Pour approfondir. Exo7 propose des cours et exercices corrigés en français. Le cours MIT 18.06 développe l'algèbre linéaire ; MIT 18.03SC les équations différentielles, Fourier et Laplace. Les contenus du MIT sont en anglais.

Garder quelques repères à portée de main

Trois familles de gestes

Choisir et transformer. x_i : choisir un élément ; x^2 : mettre au carré ; $f(x)$: appliquer une fonction ; $^\top$: transposer.

Accumuler et mesurer. Σ : additionner des termes ; $\int$: accumuler en continu ; $*$: appliquer une convolution ; E : calculer une moyenne probabiliste ; $\|x\|$: mesurer une taille. Avec Einstein, un indice répété dans un produit peut représenter une somme implicite.

Comparer et apprendre. ∂ : faire varier une entrée en fixant les autres ; ∇ : rassembler les pentes ; min : obtenir une valeur minimale ; argmin : obtenir un réglage ; $P(B \mid A)$: regarder B parmi les cas A.

Pour poursuivre avec des textes en ligne

• Mathematics for Machine Learning, Marc Peter Deisenroth, A. Aldo Faisal et Cheng Soon Ong, 2020 : fondements, dimensions, calcul vectoriel, probabilités et optimisation. Le site des auteurs donne accès au PDF.

• Dive into Deep Learning, Aston Zhang, Zachary C. Lipton, Mu Li et Alexander J. Smola : relier formules, exemples et code. Commencer par les chapitres 2.3 à 2.6.

• ParaMaths : compléter une lecture par une explication visuelle. Les volumes de la collection proposent des vidéos près des notions concernées.

• Attention Is All You Need, Ashish Vaswani et coauteurs, 2017 : reprendre l’équation de la section 3.2.1, puis examiner son rôle dans l’architecture.

Une dernière question avant de tourner la page. Pouvez-vous expliquer à quoi sert la formule, ce que ses symboles représentent et ce qu’elle ne permet pas de conclure ? Ce sont trois bons points d’appui pour poursuivre une lecture scientifique.

Des ressources pour poursuivre à son rythme

Choisissez un support lié à la difficulté du moment. Une vidéo, un dessin refait sur papier et un petit calcul peuvent suffire pour reprendre confiance.

• **Voir avant de calculer.** Voyages au pays des maths — ARTE : des films courts en français sur les graphes, les probabilités et les pavages. Après une vidéo, dessinez votre propre exemple.

• **Reprendre les bases de l'IA.** FIDLE — CNRS : découverte de l'IA, puis mathématiques et gradients, en français. Les séquences techniques demandent davantage de pratique en Python.

• **Éclairer une formule.** StatQuest — Josh Starmer : Bayes, ACP, validation croisée et descente de gradient, en anglais. Cherchez la notion dans l'index des vidéos, puis refaites un calcul du guide.

• **Passer à Python.** Machine Learnia : les notebooks des vidéos en français. Faites varier une donnée et expliquez ce qui change dans le résultat.

• **Ouvrir le calcul d'un modèle.** Homemade Machine Learning — Oleksii Trekhleb : exemples de modèles, explications mathématiques et notebooks, en anglais. Une régression simple constitue un bon premier essai.

Les noms et titres permettent de retrouver les supports si une adresse change. Gardez une trace de l'exemple que vous avez compris : question, dessin, formule et résultat.